

**EKONOMICKÁ UNIVERZITA V BRATISLAVE
FAKULTA HOSPODÁRSKEJ INFORMATIKY**

Evidenčné číslo: 103003/I/2026/36161546844576260

**GENETICKÉ ALGORITMY V ENVIRONMENTÁLNEJ
OPTIMALIZÁCII**

Diplomová práca

Rok predloženia práce

2026

Meno, priezvisko a tituly autora

Bc. Simona Mikovčíková

**EKONOMICKÁ UNIVERZITA V BRATISLAVE
FAKULTA HODPODÁRSKEJ INFORMATIKY**

**GENETICKÉ ALGORITMY V ENVIRONMENTÁLNEJ
OPTIMALIZÁCI**

Diplomová práca

Študijný program: Data science v ekonómií

Študijný odbor: Ekonómia a manažment

Školiace pracovisko: Katedra operačného výskumu a ekonometrie

Vedúci záverečnej práce: prof. Ing. Ivan Brezina, CSc.

Miesto a rok predloženia práce

Bratislava 2026

Meno, priezvisko a tituly autora

Bc. Simona Mikovčíková

Čestné vyhlásenie

Čestne vyhlasujem, že záverečnú prácu som vypracovala samostatne, a že som uviedla všetku použitú literatúru.

Dátum:

Podpis:

POĎAKOVANIE

Týmto by som chcela poďakovať môjmu školiteľovi prof. Ing. Ivan Brezina, CSc., za ochotu, pomoc a odborné rady pri vypracovaní diplomovej práce.

ABSTRAKT

MIKOVČÍKOVÁ, Simona: *Genetické algoritmy v environmentálnej optimalizácii*. – Ekonomická univerzita v Bratislave. Fakulta hospodárskej informatiky; Katedra operačného výskumu a ekonometrie. – Vedúci záverečnej práce: prof. Ing. Ivan Brezina, CSc. Bratislava: FHI EUBA, 2026, 67 strán.

Cieľom záverečnej práce je aplikácia genetických algoritmov na environmentálnu optimalizáciu zvozu komunálneho odpadu a experimentálne porovnanie dvoch modelov smerovania vozidiel – klasického kapacitne obmedzeného modelu (CVRP) a modelu zohľadňujúceho emisný náklad (PRP). Práca je rozdelená do deviatich kapitol, obsahuje 7 obrázkov a 3 tabuľky. Prvé kapitoly sa venujú súčasnému stavu odpadového hospodárstva, formulácii modelov CVRP a PRP a teoretickým základom genetických algoritmov. Praktická časť opisuje získavanie reálnych priestorových dát z mestskej časti Bratislava-Ružinov, tvorbu distančnej matice na reálnej cestnej sieti a implementáciu genetického algoritmu s permutačným kódovaním, turnajovou selekciou a krížením. Ako referenčná metóda slúži Clarkova-Wrightova heuristika. Výsledky potvrdzujú, že genetický algoritmus prekonáva referenčnú heuristiku a zohľadnenie environmentálneho kritéria môže viesť k ďalšiemu zlepšeniu kvality riešení. Hlavným výstupom práce je funkčný optimalizačný nástroj demonštrujúci potenciál genetického algoritmu v oblasti udržateľnej logistiky.

Kľúčové slová:

genetický algoritmus, environmentálna optimalizácia, zvoz komunálneho odpadu, CVRP, PRP

ABSTRACT

MIKOVČÍKOVÁ, Simona: Genetic algorithms in environmental optimization. - University of Economics in Bratislava. Faculty of Science, Department of Operational Research. - Thesis Supervisor (for dissertations supervisor): prof. Ing. Ivan Brezina, CSc. - Bratislava: Faculty abbreviation FHI EU, 2012, pages 67

The aim of the final thesis is to apply genetic algorithms to the environmental optimization of municipal waste collection and to experimentally compare two vehicle routing models, namely the classical capacitated vehicle routing problem (CVRP) and a model that takes emission costs into account (PRP). The thesis is divided into nine chapters and contains 7 figures and 3 tables. The first chapters focus on the current state of waste management, the formulation of the CVRP and PRP models, and the theoretical foundations of genetic algorithms. The practical part describes the acquisition of real spatial data from the Bratislava-Ružinov district, the creation of a distance matrix based on the real road network, and the implementation of a genetic algorithm using permutation encoding, tournament selection, and crossover. Clarke-Wright heuristic is used as a reference method. The results confirm that the genetic algorithm outperforms the reference heuristic and that taking the environmental criteria into account may lead to a further improvement in the quality of solutions. The main outcome of the thesis is a functional optimization tool demonstrating the potential of genetic algorithms in the field of sustainable logistics.

Key words:

genetic algorithm, environmental optimization, municipal waste collection, CVRP, PRP

Obsah

Úvod.....	9
1. Súčasný stav	10
1.1. Globálny kontext odpadového hospodárstva	10
1.2. Environmentálna záťaž súčasného systému zberu	10
1.3. Charakteristika logistického reťazca zberu odpadu	11
1.4. Dynamika produkcie odpadu	12
1.5. Kritické body v procese zberu odpadu	12
1.6. Kľúčové ukazovatele výkonnosti	13
1.7. Budúce trendy	13
2. Cieľ práce.....	15
3. Typy prístupov riešenia	16
3.1. Prehľad modelov	17
3.2. Zdôvodnenie výberu modelov CVRP a PRP	18
3.3. Formulácia CVRP	19
3.4. Formulácia PRP	21
3.5. Využitie modelov v praxi	23
3.6. Komplexita a zdôvodnenie použitia metaheuristiky	24
4. Genetické algoritmy	25
4.1. Reprezentácia riešenia	25
4.2. Populácia a jej význam	26
4.3. Operátory genetického algoritmu	26
4.3.1 Selekcia.....	26
4.3.2 Križenie	27
4.3.3 Mutácia.....	28
4.4. Genetický algoritmus pri riešení zvozu odpadu	28
5. Návrh a implementácia optimalizačného modelu.....	31
5.1. Popis dát	31
5.1.1 OpenStreetMap a Overpass API ako zdroj dát	31
5.1.2 Získavanie súradníc stojísk.....	32
5.1.3 Transformácia do tabuľkovej štruktúry	33
5.1.4 Reálna cestná sieť vs. vzdušná vzdialenosť	35
5.1.5 Distančná matica z OpenStreetMap	36
5.1.6 Simulácia hmotnosti odpadu	37
6. Implementácia genetického algoritmu	40

6.1. Rozdelenie permutácie na trasy – split_routes	40
6.2. Výpočet emisného nákladu trasy – route_emission	41
6.3. Výpočet celkovej prejdenej vzdialenosti trasy – route_distance	42
6.4. Genetické operátory	43
6.4.1 Turnajová selekcia	43
6.4.2 Križenie – OX (Order Crossover)	43
6.4.3 Mutácia – swap	44
6.4.4 Hlavná evolučná slučka s elitizmom	45
7. Testovanie vhodnosti parametrov genetického algoritmu	48
7.1. Finálna konfigurácia použitá v práci	49
8. Porovnávací algoritmus Clarkovej-Wrightovej heuristiky	50
8.1 Implementácia Clarkovej-Wrightovej heuristiky	51
9. Nastavenie experimentov	53
9.1. Výsledky experimentu	54
9.2. Porovnanie metód	54
9.3. Detailná analýza najlepších riešení	57
9.4. Porovnanie zaťaženia a emisného nákladu vozidiel	60
Záver	63
Zdroje:	65

Úvod

Efektívny zvoz komunálneho odpadu predstavuje dôležitú súčasť odpadového hospodárstva, ktorá má výrazný ekonomický aj environmentálny význam. Spôsob organizácie zberových trás ovplyvňuje nielen celkovú prejdenu vzdialenosť a čas, ale aj spotrebu paliva, produkciu emisií a celkovú záťaž na mestské prostredie. V súčasnosti preto už nestačí zohľadňovať iba prevádzkovú efektívnosť, ale čoraz väčší dôraz sa kladie aj na environmentálne hľadisko.

Jednou z možností riešenia takýchto úloh sú genetické algoritmy, ktoré patria medzi metaheuristické metódy vhodné na riešenie výpočtovo náročných optimalizačných problémov. Ich výhodou je schopnosť efektívne prehľadávať veľký priestor možných riešení a nachádzať kvalitné výsledky aj pri zložitejších optimalizačných úlohách.

Táto diplomová práca zaoberá sa analýzou a možnosťou využitia genetických algoritmov v environmentálnej optimalizácii na príklade zvozu komunálneho odpadu. Pozornosť bude zameraná na porovnanie klasického modelu CVRP, založeného na minimalizácii prejdenej vzdialenosti, a modifikovaného modelu PRP, ktorý zohľadňuje aj emisný náklad závislý od aktuálnej hmotnosti vozidla. Oba prístupy budú aplikované na reálne priestorové dáta z mestskej časti Bratislava-Ružinov.

V práci sú najskôr priblížené východiská odpadového hospodárstva, modely smerovania vozidiel a princípy genetických algoritmov. Následne je opísaný postup získavania a spracovania dát, tvorba vzdialenostnej matice, implementácia genetického algoritmu a experimentálne porovnanie dosiahnutých výsledkov. Na základe týchto výsledkov je možné posúdiť využiteľnosť genetického algoritmu pri riešení úlohy zvozu komunálneho odpadu z hľadiska prejdenej vzdialenosti aj environmentálnej záťaže.

1. Súčasný stav

1.1. Globálny kontext odpadového hospodárstva

Odpadové hospodárstvo je v súčasnosti považované za jednu z významných environmentálnych a socio-ekonomických výziev, ktoré úzko súvisia s rastúcou urbanizáciou a zvyšujúcou sa spotrebou obyvateľstva. S rozvojom miest a rastom počtu obyvateľov sa dlhodobo zvyšuje aj množstvo komunálneho odpadu, čo vytvára tlak na mestskú infraštruktúru, verejné financie aj životné prostredie. Problematika odpadu sa tak nevzťahuje len na jeho samotný zber a spracovanie, ale aj na širšie otázky efektívnosti, nákladovosti a udržateľnosti celého systému.

V roku 2012 bolo v mestách celosvetovo vyprodukovaných približne 1,3 miliardy ton tuhého komunálneho odpadu ročne, pričom náklady spojené s jeho správou dosiahli 205,4 miliardy amerických dolárov. Prognózy zároveň naznačovali, že do roku 2025 sa tento objem zvýši na 2,2 miliardy ton a súvisiace náklady vzrastú na 375,5 miliardy dolárov [1]. Z uvedeného vývoja je zrejmé, že rast produkcie odpadu predstavuje nielen environmentálny, ale aj výrazný ekonomický problém.

V rámci celého reťazca nakladania s odpadom zohrávajú významnú úlohu najmä zber a preprava, ktoré patria k finančne najnáročnejším činnostiam. Odhaduje sa, že tieto logistické procesy tvoria približne 60 až 80 % celkových nákladov odpadového hospodárstva [1]. Zároveň ide o činnosti, ktoré sú spojené s negatívnymi vplyvmi na životné prostredie, predovšetkým prostredníctvom emisií skleníkových plynov, najmä oxidu uhličitého [2].

Práve z tohto dôvodu sa do popredia dostávajú princípy zelenej a reverznej logistiky, prostredníctvom ktorých sa usiluje o znižovanie ekologickej stopy dopravných a logistických procesov. Pozornosť je pritom venovaná najmä redukcii emisií, znižovaniu energetickej náročnosti a efektívnejšiemu plánovaniu prepravy [1].

1.2. Environmentálna záťaž súčasného systému zberu

Súčasný systém zberu komunálneho odpadu predstavuje významnú environmentálnu záťaž, najmä preto, že je vo veľkej miere založený na využívaní ťažkých vozidiel s naftovým pohonom. Mestské oblasti sa podieľajú na viac ako 70 % celosvetových emisií oxidu uhličitého, pričom významná časť týchto emisií pochádza

práve zo sektora cestnej dopravy [2]. V rámci neho patria smetiarske vozidlá medzi špecifické zdroje znečistenia, keďže ich prevádzka je spojená s častým zastavovaním, opätovným rozbiehaním, chodom motora na voľnobeh a vysokou energetickou náročnosťou pri manipulácii s odpadom.

Tieto prevádzkové charakteristiky vedú k zvýšenej spotrebe paliva a následne aj k vyšším emisiám skleníkových plynov, predovšetkým oxidu uhličitého. Negatívny vplyv je zároveň zosilňovaný rastúcim objemom produkovaného odpadu. Ako ukazujú údaje z Číny, množstvo komunálneho odpadu vzrástlo zo 170 miliónov ton v roku 2012 na 260 miliónov ton v roku 2023 [3], čo poukazuje na dlhodobý tlak na životné prostredie aj na zberové systémy.

Pri hodnotení dopadov zberu odpadu však nestačí zohľadňovať len samotné emisie. Významné sú aj sekundárne externality, ako je riziko znečistenia komunikácií pri preprave mokrého alebo biologicky rozložiteľného odpadu a tiež hluková záťaž, ktorá znižuje kvalitu života obyvateľov v mestských oblastiach. Aj z tohto dôvodu sa v moderných logistických modeloch uplatňujú časové okná zberu a do popredia sa dostávajú aj ekologickejšie alternatívy, napríklad elektrické smetiarske vozidlá, ktoré sa vyznačujú nižšou hlučnosťou a priaznivejším environmentálnym profilom [3].

1.3. Charakteristika logistického reťazca zberu odpadu

Ak má byť systém zberu odpadu optimalizovaný z environmentálneho hľadiska, je najskôr potrebné pochopiť, ako celý proces v skutočnosti funguje a ktoré jeho časti spôsobujú najväčšie problémy. Zber odpadu totiž nepredstavuje len jednoduchý presun vozidla medzi jednotlivými stojiskami, ale ide o pomerne zložitý logistický proces, do ktorého vstupuje viacero technických, prevádzkových aj environmentálnych faktorov.

Z matematického hľadiska patrí plánovanie zberových trás medzi zložené optimalizačné úlohy. Problémy smerovania vozidiel, ako je napríklad VRP (Vehicle Routing Problem), sa zaraďujú medzi NP-ťažké problémy, čo znamená, že pri väčšom počte bodov je ich presné riešenie výpočtovo veľmi náročné. Exaktné metódy sú preto využiteľné najmä pri menších úlohách, zatiaľ čo pri rozsiahlejších sieťach sa v praxi častejšie používajú heuristiky a metaheuristiky, ktoré síce nezaručujú úplne optimálne riešenie, ale umožňujú nájsť dostatočne kvalitné riešenia v prijateľnom čase [1].

Z logistického pohľadu zároveň nemožno zber odpadu vnímať ako jednotný proces. Pri plánovaní je potrebné rozlišovať medzi jednotlivými druhmi odpadu, najmä medzi suchou zložkou a biologicky rozložiteľným odpadom. Práve pri mokrom odpade vznikajú špecifické komplikácie, ktoré sa pri iných druhoch odpadu nemusia prejavovať v takej miere. Ide najmä o vyššie riziko sekundárneho znečistenia počas prepravy, napríklad pri úniku kvapalín, ale aj o potrebu smerovať odpad do vhodných koncových zariadení, ako sú napríklad bioplynové stanice [3].

1.4. Dynamika produkcie odpadu

Pri plánovaní zberových trás predstavuje jeden z najväčších problémov neistota, pretože vopred nie je možné presne určiť, ako veľmi budú jednotlivé kontajnery naplnené. Množstvo odpadu sa môže meniť v závislosti od viacerých faktorov, napríklad od lokality, frekvencie vývozu či sezónnych výkyvov. Práve táto premenlivosť spôsobuje, že pri tvorbe trás nemožno vždy vychádzať len z pevných a presne daných hodnôt.

V odbornej literatúre sa preto využíva stochastický prístup, v rámci ktorého sa množstvo odpadu v jednotlivých zberných bodoch modeluje ako náhodná premenná. Namiesto striktného stanoveného kapacitného obmedzenia vozidla sa uvažuje s pravdepodobnosťou, že celkové množstvo odpadu na trase neprekročí jeho nosnosť. Takýto prístup sa považuje za realistickejší, pretože lepšie zachytáva skutočné podmienky prevádzky a umožňuje navrhovať robustnejšie trasy, ktoré sú odolnejšie voči bežným výkyvom v produkcii odpadu [4].

1.5. Kritické body v procese zberu odpadu

Ak á byť environmentálny dopad zberu odpadu znižovaný, je potrebné určiť tie časti procesu, v ktorých vzniká najväčšia záťaž. Jednou z najvýznamnejších fáz je samotná preprava medzi jednotlivými zbernými bodmi. Práve počas jazdy dochádza k spaľovaniu paliva a vzniku emisií oxidu uhličitého. Zároveň platí, že tieto emisie nie sú počas celej trasy rovnaké, ale menia sa v závislosti od aktuálnej hmotnosti vozidla, ktorá sa postupne zvyšuje s pribúdajúcim odpadom [5].

Ďalším dôležitým bodom je presun plne naloženého vozidla na miesto finálneho spracovania alebo zneškodnenia odpadu. V tomto prípade nezávisí environmentálna záťaž len od samotnej jazdy, ale aj od toho, kde sa skládka alebo spracovateľské zariadenie nachádza. Ak je toto miesto príliš vzdialené, predlžujú sa takzvané neproduktívne prejazdy,

pri ktorých už nie je zbieraný ďalší odpad, no vozidlo stále spotrebúva palivo a produkuje emisie. Aj preto je otázka vhodného umiestnenia týchto zariadení z pohľadu efektívnosti celého systému veľmi dôležitá [4].

1.6. Kľúčové ukazovatele výkonnosti

Pri hodnotení efektívnosti zberových trás sa sleduje viacero ukazovateľov, pričom ich výber závisí od toho, či je dôraz kladený viac na prevádzkovú alebo environmentálnu stránku problému. V praxi už totiž nestačí sledovať len to, ako krátka je trasa, ale aj to, aký má dopad na životné prostredie a ako efektívne sú využité dostupné vozidlá.

Z environmentálneho hľadiska sa najčastejšie hodnotia emisie CO₂. V odborných modeloch sa pritom vychádza z toho, že množstvo vyprodukovaných emisií nezávisí len od prejdenej vzdialenosti, ale aj od aktuálneho zaťaženia vozidla[6]. Vďaka tomu je možné presnejšie odhadnúť, akú uhlíkovú záťaž konkrétna trasa predstavuje. V niektorých prístupoch sa preto sleduje nielen samotná vzdialenosť, ale priamo uhlíková stopa celej trasy od výjazdu vozidla až po jeho návrat.

Pri elektrických vozidlách sa do popredia dostáva najmä spotreba energie vyjadrená v kWh. Nezávisí pritom iba od vzdialenosti, ale aj od ďalších faktorov, ako je prevádzka hydraulických mechanizmov, zdvíhanie kontajnerov, zhutňovanie odpadu alebo sklon vozovky[2]. Aj z tohto dôvodu je pri hodnotení takýchto vozidiel potrebné uvažovať širšie než len cez počet prejdenej kilometrov.

Z prevádzkového hľadiska však zostáva veľmi dôležitým ukazovateľom aj celková prejdenej vzdialenosť. Tá sa objavuje vo väčšine optimalizačných modelov, či už ako hlavný cieľ minimalizácie, alebo ako porovnávacia veličina pri hodnotení ekologickejších variantov riešenia. Dôležité je aj využitie kapacity vozidla, pretože práve ono ukazuje, nakoľko efektívne je zber organizovaný. V modernejších modeloch sa pritom zohľadňuje aj neistota spojená s množstvom odpadu na jednotlivých stojiskách, aby výsledné riešenia lepšie zodpovedali reálnej prevádzke [3].

1.7. Budúce trendy

Oblasť optimalizácie zberu odpadu sa stále vyvíja a popri tradičných prístupoch sa čoraz viac objavujú aj nové smery, ktoré môžu v budúcnosti zohrávať dôležitú úlohu. Jedným z nich je dynamické plánovanie trás v reálnom čase. V budúcnosti by mohli byť

do tohto procesu vo väčšej miere zapojené inteligentné systémy, ktoré by dokázali priebežne vyhodnocovať naplnenosť kontajnerov a podľa toho upravovať trasu vozidla. Takýto prístup by umožnil obsluhovať prednostne tie stojiská, ktoré to skutočne vyžadujú, a tým by sa znížila spotreba energie aj celková časová náročnosť zberu.

Významná pozornosť sa venuje aj bioodpadu, pri ktorom nevzniká len problém samotnej prepravy, ale aj otázka času medzi jeho vznikom a spracovaním. Práve pri biologicky rozložiteľnom odpade je dôležité, aby bol čo najrýchlejšie dopravený na vhodné spracovanie, pretože pri jeho rozklade vzniká metán, ktorý patrí medzi veľmi výrazné skleníkové plyny. Z tohto dôvodu sa dá očakávať, že v budúcnosti bude ešte väčší dôraz kladený na správne umiestnenie spracovateľských zariadení a efektívne nastavenie zberových trás [2].

Výrazným trendom je aj nástup elektromobility. Elektrické smetiarske vozidlá prinášajú viacero výhod, najmä nižšiu hlučnosť a obmedzenie lokálnych emisií. Na druhej strane však prinášajú aj nové obmedzenia, napríklad kratší dojazd, potrebu dobíjania alebo vyššiu citlivosť spotreby energie na profil terénu. Aj preto bude potrebné, aby sa optimalizačné modely týmto novým podmienkam prispôbovali. Práve v tomto smere sa ukazuje potenciál genetických algoritmov, ktoré dokážu pracovať aj so zložitejšími obmedzeniami a hľadať vhodné riešenia aj v komplikovanejších podmienkach [2].

V tejto kapitole bol priblížený súčasný stav environmentálnej optimalizácie zberu odpadu s dôrazom na faktory, ktoré ovplyvňujú efektívnosť a udržateľnosť zberových systémov. Ukazuje sa, že pri modernom plánovaní už nestačí sledovať iba minimalizáciu prejdenej vzdialenosti. Do popredia sa čoraz viac dostávajú aj environmentálne ukazovatele, práca s neistotou a nové technologické možnosti, ktoré vytvárajú priestor pre využitie pokročilejších optimalizačných prístupov, vrátane genetických algoritmov.

2. Cieľ práce

Hlavným cieľom tejto diplomovej práce je využiť genetický algoritmus pri optimalizácii zvozu komunálneho odpadu a porovnať dva prístupy riešenia, a to model CVRP a zjednodušený model PRP. Model CVRP je zameraný na minimalizáciu celkovej prejdenej vzdialenosti, zatiaľ čo zjednodušený model PRP zohľadňuje emisný náklad závislý od aktuálnej hmotnosti vozidla.

Použitie genetického algoritmu vyplýva z charakteru riešeného problému, keďže úlohy typu CVRP a PRP patria medzi NP-tažké optimalizačné problémy. Pri väčšom počte stojísk preto nie je praktické využívať exaktné metódy, a z tohto dôvodu bol v práci zvolený metaheuristický prístup, ktorý umožňuje nájsť kvalitné riešenia v prijateľnom čase.

Na splnenie hlavného cieľa je potrebné najskôr spracovať teoretické východiská problematiky, charakterizovať odpadové hospodárstvo, environmentálnu záťaž zberu odpadu, modely smerovania vozidiel a princípy genetických algoritmov. Následne je potrebné získať a spracovať reálne priestorové dáta o stojiskách odpadu v mestskej časti Bratislava-Ružinov, vytvoriť distančnú maticu na základe reálnej cestnej siete a pripraviť vstupné údaje pre riešenie úlohy.

Ďalším cieľom práce je navrhnúť a implementovať genetický algoritmus v programovacom jazyku Python pre model CVRP aj pre zjednodušený model PRP. Súčasťou riešenia je aj implementácia Clarkovej-Wrightovej heuristiky ako porovnávacej metódy. Následne bude genetický algoritmus experimentálne overený pri viacerých nastaveniach parametrov a výsledné riešenia budú porovnané z hľadiska prejdenej vzdialenosti, emisného nákladu, štruktúry trás a stability algoritmu.

Na základe dosiahnutých výsledkov bude možné zhodnotiť využitie genetického algoritmu pri riešení úlohy zvozu komunálneho odpadu pre model CVRP a zjednodušený model PRP.

3. Typy prístupov riešenia

V odbornej literatúre sa pri riešení problému smerovania vozidiel (Vehicle Routing Problem, VRP) rozlišuje viacero prístupov. Základné delenie oddeľuje exaktné algoritmy od aproximačných metód. Exaktné algoritmy, ako napríklad generovanie stĺpcov alebo dynamické programovanie, dokážu nájsť optimálne riešenie, ich využitie je však obmedzené vysokou výpočtovou náročnosťou. V praxi sa preto uplatňujú najmä pri menších úlohách s nižším počtom vrcholov. Pri rozsiahlejších problémoch sa častejšie využívajú aproximačné metódy, ktoré síce nezaručujú úplne optimálne riešenie, ale dokážu poskytnúť dostatočne kvalitné výsledky v prijateľnom čase, čo je pri reálnych aplikáciách rozhodujúce [7].

Aproximačné metódy sa zvyčajne delia na klasické heuristiky a metaheuristiky. Medzi klasické heuristiky patria napríklad konštrukčné postupy, ako je metóda najbližšieho suseda alebo Clarkov-Wrightov algoritmus. Využívajú sa aj dvojfázové prístupy, pri ktorých sa zákazníci najskôr rozdelia do skupín a až následne sa rieši samotné smerovanie v rámci jednotlivých skupín. Osobitnú skupinu tvoria heuristiky lokálneho zlepšovania, ktoré sa zameriavajú buď na úpravy v rámci jednej trasy, alebo na presuny medzi viacerými trasami [7].

Druhú významnú skupinu aproximačných metód predstavujú metaheuristiky. Ide o pokročilejšie prístupy, pri ktorých sa hľadá čo najlepšia rovnováha medzi kvalitou riešenia a výpočtovým časom. Do tejto skupiny patria napríklad metódy miestneho vyhľadávania, ako sú Tabu Search, simulované žíhanie alebo metódy variabilného okolia. Okrem nich sa využívajú aj populačné metaheuristiky, medzi ktoré sa zaraďujú genetické algoritmy, optimalizácia rojom častíc alebo optimalizácia mravčou kolóniou. Tieto metódy pracujú s viacerými riešeniami naraz a nové riešenia vznikajú ich kombinovaním a postupným vylepšovaním [7].

Genetický algoritmus patrí medzi stochastické evolučné metódy a je inšpirovaný princípmi prirodzeného výberu. Jeho fungovanie je založené na práci s populáciou riešení, ktoré sa v priebehu výpočtu menia a vyvíjajú pomocou operátorov, ako sú selekcia, kríženie a mutácia. Výhodou tohto prístupu je schopnosť efektívne prehľadávať rozsiahly priestor možných riešení a zároveň sa vo väčšej miere vyhnúť uviaznutiu v lokálnom optime. Práve

preto sa genetické algoritmy považujú za vhodný nástroj pri riešení zložitejších optimalizačných úloh, medzi ktoré patrí aj smerovanie vozidiel [7].

3.1. Prehľad modelov

V oblasti plánovania trás existuje viacero modelov, ktoré vznikli ako reakcia na rôzne praktické požiadavky a obmedzenia. Jednotlivé varianty sa od seba odlišujú najmä tým, aké podmienky zohľadňujú, napríklad kapacitu vozidla, čas obsluhy, neistotu v dátach alebo environmentálne dopady. V nasledujúcom texte sú stručne predstavené vybrané modely využívané pri riešení problémov plánovania trás:

VRP (Vehicle Routing Problem) je základný model smerovania vozidiel, pri ktorom sa rieši rozvoz alebo zber pomocou viacerých vozidiel vychádzajúcich z jedného depa. Cieľom je navrhnúť také trasy, aby boli zákazníci obslužení pri čo najnižších dopravných nákladoch.

CVRP (Capacitated Vehicle Routing Problem) rozširuje základný VRP o kapacitné obmedzenie vozidiel. Každé vozidlo má stanovenú maximálnu nosnosť, ktorá nesmie byť počas trasy prekročená. Práve tento model patrí medzi najčastejšie využívané pri úlohách zberu odpadu, keďže rešpektuje obmedzenú kapacitu zberových vozidiel.

SVRP (Stochastic Vehicle Routing Problem) predstavuje prístup, pri ktorom nie sú všetky vstupné údaje pevne dané. Dopyt, cestovné časy alebo náklady môžu byť modelované ako náhodné premenné, čím sa lepšie zachytáva neistota reálnej prevádzky[7].

DVRP (Dynamic Vehicle Routing Problem) rieši situácie, v ktorých sa podmienky počas realizácie trasy menia. Môže ísť napríklad o nové požiadavky, zmeny v doprave alebo nečakané obmedzenia, na ktoré je potrebné reagovať priebežnou úpravou plánu[7].

GVRP (Green Vehicle Routing Problem) rozširuje klasický model o environmentálny rozmer. Okrem ekonomických nákladov sa pri ňom sledujú aj ukazovatele ako spotreba paliva alebo množstvo vyprodukovaných emisií[8].

PRP (Pollution Routing Problem) predstavuje rozšírenie VRP, v ktorom sa okrem vzdialenosti zohľadňujú aj emisie, spotreba paliva, čas jazdy a ďalšie prevádzkové náklady. Do výpočtu vstupujú aj faktory, ako je rýchlosť vozidla a hmotnosť nákladu, vďaka čomu dokáže tento model realistickejšie zachytiť environmentálne dopady dopravy [6].

3.2. Zdôvodnenie výberu modelov CVRP a PRP

Pri výbere vhodného modelu pre optimalizáciu zvozu komunálneho odpadu bolo potrebné zohľadniť dve základné skutočnosti, ktoré túto úlohu najviac ovplyvňujú. Prvou je obmedzená kapacita zberových vozidiel, ktorá počas zberu nemôže byť prekročená. Druhou je environmentálny dopad prepravy, najmä produkcia emisií, ktorá nezávisí len od dĺžky trasy, ale aj od toho, ako sa počas jazdy mení hmotnosť vozidla pri postupnom nakladaní odpadu.

Z tohto dôvodu boli v praktickej časti práce zvolené dva modely, ktoré umožňujú zachytiť oba tieto aspekty. Prvým z nich je **CVRP (Capacitated Vehicle Routing Problem)**, teda kapacitný problém smerovania vozidiel. Tento model bol vybraný preto, že prirodzene zodpovedá podmienkam zberu odpadu, kde má každé vozidlo presne určenú maximálnu nosnosť. Pri jeho použití je možné hľadať také trasy, pri ktorých sa minimalizuje celková prejdená vzdialenosť a zároveň sa neprekročí kapacita vozidla. Práve preto sa CVRP považuje za jeden zo základných modelov využívaných pri riešení zberových a distribučných úloh.

Samotný model CVRP však zohľadňuje najmä prevádzkovú stránku problému a jeho hlavný cieľ je postavený na minimalizácii vzdialenosti. Z environmentálneho pohľadu to predstavuje určité obmedzenie, pretože sa tým nepriamo predpokladá, že dopad vozidla je počas celej trasy rovnaký. V prípade zvozu odpadu však tento predpoklad neplatí, keďže vozidlo je na začiatku trasy prázdne a jeho hmotnosť sa pri ďalších zastávkach postupne zvyšuje. Rastúca hmotnosť pritom vplýva aj na spotrebu paliva a množstvo vytvorených emisií.

Práve z tohto dôvodu bol ako druhý model zvolený **PRP (Pollution Routing Problem)**, teda problém smerovania s ohľadom na znečistenie. Tento model rozširuje klasický prístup tým, že do hodnotenia trás zahŕňa aj environmentálny rozmer. Jeho výhodou je, že umožňuje pracovať s tým, že emisie vozidla sa menia v závislosti od aktuálneho zaťaženia. V pôvodnej formulácii modelu sa zohľadňuje aj rýchlosť vozidla a ďalšie faktory, no pre potreby tejto práce bola použitá zjednodušená verzia, v ktorej sa emisný náklad vyjadruje ako súčin prejdenej vzdialenosti a okamžitej hmotnosti vozidla na jednotlivých úsekoch trasy [6].

Takéto zjednodušenie bolo zvolené zámerne. Na jednej strane umožňuje jednoduchšie a prehľadnejšie porovnanie s modelom CVRP, keďže oba modely pracujú s rovnakou množinou riešení a odlišujú sa najmä v tom, čo sa v nich optimalizuje. Na druhej strane ide o prístup, ktorý je výpočtovo menej náročný a zároveň vhodný na implementáciu pomocou genetického algoritmu. Aj napriek zjednodušeniu však zostáva zachovaný základný princíp, že ťažšie vozidlo vytvára pri jazde vyššiu environmentálnu záťaž než vozidlo s menším zaťažením [10].

Použitie oboch modelov tak vytvára vhodný základ na porovnanie dvoch rozdielnych pohľadov na tú istú úlohu. Kým model CVRP je zameraný predovšetkým na minimalizáciu vzdialenosti, model PRP kladie väčší dôraz na environmentálnu stránku prepravy. Vzájomné porovnanie ich výsledkov umožňuje posúdiť, do akej miery môže optimalizácia s ohľadom na emisie priniesť priaznivejšie riešenia než klasický prístup založený len na dĺžke trás.

3.3. Formulácia CVRP

Kapacitný problém smerovania vozidiel (CVRP) je najčastejšie študovanou základnou verziou problému smerovania vozidiel (VRP) a z matematického hľadiska sa modeluje pomocou teórie grafov. CVRP je definovaný na úplnom grafe $G=(N_0, A)$, a množina hrán A sú vymedzené nasledovne:

Množiny a parametre:

$N = \{1, 2, \dots, n\}$ – množina všetkých vrcholov, v kontexte tejto práce zberných stojísk

$N_0 = N \cup \{0\}$ – množina všetkých vrcholov vrátane centrálného depa, ktoré je reprezentované vrcholom 0

d_{ij} - vzdialenosť medzi vrcholmi $i, j \in N_0$

q_i – dopyt (množstvo odpadu) na zbernom stojisku $i \in N$

Q - kapacita vozidla, ktorá je pre všetky vozidlá flotily identická.

Rozhodovacie premenné:

$x_{ij} \in \{0, 1\}$ – binárna premenná, ktorá nadobúda hodnotu 1, ak vozidlo prechádza priamo z vrcholu i do vrcholu j , a hodnotu 0 v opačnom prípade, pre všetky, $j \in N_0$, $i \neq j$.

u_i – spojitá pomocná premenná vyjadrujúca množstvo odpadu naloženého na vozidle po obslúžení stojiska $i \in N$. Táto premenná slúži na elimináciu čiastkových cyklov a zároveň na kontrolu kapacitného obmedzenia.

Účelová funkcia:

Cieľom optimalizácie je minimalizovať celkovú prejdenú vzdialenosť všetkých vozidiel, čo je vyjadrené nasledujúcim vzťahom:

$$\min f(X, u) = \sum_{i \in N_0} \sum_{j \in N_0} d_{ij} x_{ij}$$

Obmedzenia modelu:

Každé stojisko je navštívené práve raz. To znamená, že každý vrchol $j \in N$ musí existovať práve jedna hrana, po ktorej vozidlo do tohto vrcholu príde, a práve jedna hrana, po ktorej z neho odíde:

$$\sum_{i \in N_0, i \neq j} x_{ij} = 1, \quad j \in N$$

$$\sum_{j \in N_0, i \neq j} x_{ij} = 1, \quad i \in N$$

Na elimináciu čiastkových cyklov a zároveň na zabezpečenie kapacitného obmedzenia sa používa vzťah medzi pomocnými premennými u_i a u_j :

$$u_i - u_j + Q \cdot x_{ij} \leq Q - q_j, \quad i \in N_0, j \in N, i \neq j$$

Zároveň musí platiť, že množstvo odpadu naloženého po obslúžení každého stojiska je aspoň rovné jeho požiadavke a zároveň neprekročí kapacitu vozidla:

$$q_i \leq u_i \leq Q, \quad i \in N$$

Pri odchode z depa sa predpokladá, že vozidlo je prázdne, preto pre vrchol 0 platí:

$$u_0 = 0$$

Premenné x_{ij} sú binárne, pričom uvažované sú len hrany medzi rôznymi vrcholmi:

$$x_{ij} \in \{0,1\}, \quad i, j \in N_0, i \neq j$$

Uvedená formulácia, prevzatá z práce [8], predstavuje štandardný matematický zápis úlohy CVRP. Vychádza z Millerovej-Tuckerovej-Zemlinovej formulácie, ktorá sa v odbornej literatúre bežne používa pri modelovaní kapacitných obmedzení a odstraňovaní čiastkových cyklov. Uvedená formulácia predstavuje presný matematický opis problému smerovania vozidiel s obmedzenou kapacitou a slúži ako východisko pre jeho riešenie[9].

3.4. Formulácia PRP

Na rozdiel od modelu CVRP, ktorý je zameraný najmä na minimalizáciu prejdenej vzdialenosti, model PRP rozširuje pohľad na riešený problém aj o environmentálny aspekt. Jeho význam spočíva v tom, že spotreba paliva a s ňou súvisiace emisie CO₂ sa počas trasy nemenia náhodne, ale vo veľkej miere závisia od aktuálnej hmotnosti vozidla [7]. Ak by sa tento faktor nezohľadnil, mohli by byť ako optimálne vyhodnotené aj také trasy, ktoré sú síce kratšie, no z environmentálneho hľadiska menej vhodné.

Model PRP bol pôvodne predstavený v práci [7] ako rozšírenie klasického problému smerovania vozidiel. Na rozdiel od tradičných modelov sa v ňom nehodnotí len prejdená vzdialenosť, ale aj spotreba paliva, emisie skleníkových plynov, čas jazdy a ďalšie prevádzkové náklady [7]. V tejto práci však bola použitá zjednodušená verzia tohto modelu, v ktorej sa pozornosť sústreďuje najmä na vzťah medzi emisiami a aktuálnou hmotnosťou vozidla. Rýchlosť vozidla sa pritom považuje za konštantnú a časové okná sa do modelu nezahŕňajú.

Takto zvolený prístup umožňuje jednoduchšie sledovať, ako poradie jednotlivých zastávok ovplyvňuje celkovú environmentálnu záťaž trasy. Zároveň je zachovaný základný princíp, že s rastúcou hmotnosťou vozidla rastie aj jeho spotreba paliva a množstvo vyprodukovaných emisií na kilometer jazdy.

Cieľom modifikovaného modelu PRP je minimalizovať celkovú environmentálnu záťaž trasy, ktorá je v tejto práci vyjadrená ako súčet súčinov prejdenej vzdialenosti a aktuálnej celkovej hmotnosti vozidla na jednotlivých úsekoch trasy.

Formulácia zjednodušeného PRP modelu:

Model vychádza z rovnakej grafovej štruktúry $G=(N_0,A)$ a množín ako CVRP.

Parametre:

d_{ij} - vzdialenosť medzi vrcholmi $i,j \in N_0$

q_i – dopyt (množstvo odpadu) na zbernom stojisku $i \in N$

Q - kapacita vozidla, ktorá je pre všetky vozidlá flotily identická

w – hmotnosť prázdneho vozidla [kg].

Rozšírené rozhodovacie premenné:

$x_{ij} \in \{0,1\}$ – rovnako ako v CVRP určuje, či je hrana (i,j) súčasťou trasy

$f_{ij} \geq 0$ – spojitá premenná reprezentujúca množstvo nákladu (kg), ktoré je prepravované na hrane (i,j) . Táto premenná umožňuje zachytiť zmenu hmotnosti vozidla počas trasy.

Účelová funkcia:

Na rozdiel od modelu CVRP, kde sa minimalizuje celková prejdená vzdialenosť, sa v tomto prípade minimalizuje emisný náklad, ktorý je vyjadrený ako súčin vzdialenosti a aktuálnej hmotnosti vozidla na danom úseku trasy:

$$\min f(X, f) = \sum_{i \in N_0} \sum_{j \in N_0} d_{ij}(w \cdot x_{ij} + f_{ij})$$

Táto formulácia vyjadruje, že emisie na hrane (i,j) závisia od súčtu hmotnosti prázdneho vozidla w a množstva odpadu, ktoré je na danom úseku práve prepravované f_{ij} .

Obmedzenia modelu:

Každé stojisko je navštívené práve raz. To znamená, že každý vrchol $j \in N$ musí existovať práve jedna hrana, po ktorej vozidlo do tohto vrcholu príde, a práve jedna hrana, po ktorej z neho odíde:

$$\sum_{i \in N_0, i \neq j} x_{ij} = 1, \quad \forall j \in N$$

$$\sum_{j \in N_0, i \neq j} x_{ij} = 1, \quad \forall i \in N$$

Predpokladá sa, že vozidlo opúšťa depo prázdne, preto platí:

$$\sum_{j \in N} f_{0j} = 0$$

Množstvo nákladu, ktoré vstúpi do uzla i vstupuje, mínus množstvo nákladu, ktoré z neho odchádza, sa musí rovnať množstvu vyzbieraného odpadu q_i na danom stojisku:

$$\sum_{j \in N_0, i \neq j} f_{ji} - \sum_{j \in N_0, i \neq j} f_{ij} = q_i, \quad \forall i \in N$$

Náklad môže byť prepravovaný len po hranách, ktoré sú skutočne súčasťou trasy $x_{ij} = 1$. Zároveň nesmie byť prekročená kapacita vozidla. Preto platí:

$$0 \leq f_{ij} \leq Q \cdot x_{ij}, \quad i \in N_0, \forall j \in N_0, \quad i \neq j$$

Premenné x_{ij} sú binárne, pričom uvažované sú len hrany medzi rôznymi vrcholmi:

$$x_{ij} \in \{0,1\}, \quad i, j \in N_0, i \neq j$$

Prezentovaný modifikovaný model PRP predstavuje zjednodušenú, no pre účely tejto práce postačujúcu verziu, ktorá zachytáva základný vzťah medzi environmentálnou záťažou a postupne narastajúcim zaťažením vozidla počas zberu.

3.5. Využitie modelov v praxi

Modely CVRP a PRP nachádzajú praktické uplatnenie pri riešení reálnych problémov spojených so zberom a prepravou odpadu. Ich využitie sa spája nielen so zlepšením prevádzkovej efektívnosti, ale aj so znižovaním environmentálnej záťaže a celkových nákladov.

V prípade modelu PRP bolo v podmienkach Spojeného kráľovstva preukázané, že jeho aplikácia pri rozvoze alebo zbere môže viesť k zníženiu emisií CO₂ približne o 5 až 7 % v porovnaní s riešeniami, ktoré zohľadňujú iba prejdený čas alebo vzdialenosť. Ukazuje sa tak, že zohľadnenie rýchlosti jazdy a hmotnosti nákladu môže významne prispieť k zníženiu uhlíkovej stopy logistických procesov [6].

Praktické prínosy optimalizačných prístupov boli potvrdené aj pri riešení zberu komunálneho odpadu v čínskom meste Huzhou. V tomto prípade bol na problém smerovania vozidiel aplikovaný upravený mravčí algoritmus, pričom výsledkom bolo

zníženie prevádzkových nákladov zberu o 31,2 %, pokles fixných nákladov o 60 % a redukcia celkových uhlíkových emisií o 25,3 % [10].

Ďalší príklad pochádza z mestskej časti Campolide v Lisabone, kde bol genetický algoritmus využitý pri optimalizácii takzvaného door-to-door zberu odpadu. Riešenie vychádzalo z historických a otvorených dát o produkcii odpadu a ukázalo, že aj pri reálnych podmienkach je možné pomocou genetického algoritmu efektívne plánovať kapacity viacerých zberných vozidiel, znižovať celkovú prejdenú vzdialenosť a zároveň obmedzovať environmentálnu záťaž mestského prostredia [1].

3.6. Komplexita a zdôvodnenie použitia metaheuristiky

Kapacitný problém smerovania vozidiel (CVRP) patrí medzi NP-ťažké optimalizačné problémy [9]. To znamená, že s rastúcim počtom stojísk rýchlo narastá aj počet možných riešení. Pri väčších úlohách je preto veľmi náročné nájsť optimálne riešenie pomocou exaktných metód v prijateľnom čase. Pri n stojiskách môže počet možných usporiadaní dosahovať rádovo $n!$, pričom v prípade CVRP je problém ešte zložitejší o kapacitné obmedzenia jednotlivých vozidiel.

Z tohto dôvodu sa pri riešení väčších inštancií často používajú heuristiky a metaheuristiky [9]. Ich cieľom nie je preskúmať celý priestor riešení, ale nájsť dostatočne kvalitné riešenie v rozumnom čase. Hoci nezaručujú nájdenie globálne optimálneho riešenia, v praxi sa pri zložitých úlohách ukazujú ako vhodný prístup.

V tejto práci bol preto použitý genetický algoritmus, a to pre model GA-CVRP aj GA-PRP. Dôvodom jeho výberu je schopnosť pracovať s veľkým priestorom riešení a zároveň zohľadniť rôzne obmedzenia riešeného problému. Genetický algoritmus patrí medzi populačné metaheuristiky, teda pracuje s viacerými riešeniami naraz a tie následne postupne upravuje pomocou selekcie, kríženia a mutácie.

Použitie genetického algoritmu je v tejto práci odôvodnené tým, že umožňuje nájsť kvalitné riešenia v prijateľnom výpočtovom čase aj pri problémoch, kde by presné riešenie bolo výpočtovo príliš náročné[9]. Zároveň umožňuje použiť rovnaký princíp riešenia pri dvoch rôznych optimalizačných cieľoch, teda pri minimalizácii vzdialenosti v modeli GA-CVRP aj pri minimalizácii emisného nákladu v modeli GA-PRP.

4. Genetické algoritmy

V tejto kapitole je pozornosť venovaná genetickým algoritmom, ktoré patria medzi často využívané metaheuristické metódy pri riešení zložitých optimalizačných úloh. Ich princíp vychádza z evolučných procesov známych z prírody, najmä z prirodzeného výberu a genetickej dedičnosti. Prvé myšlienky spojené s využitím evolučných princípov vo výpočtovej technike sa objavili už v polovici 20. storočia, za zakladateľa genetických algoritmov je však najčastejšie považovaný John H. Holland, ktorý ich systematicky rozpracoval vo svojej práci *Adaptation in Natural and Artificial Systems* z roku 1975. Cieľom jeho prístupu bolo preniesť princíp adaptácie a výberu do oblasti riešenia výpočtovo náročných problémov.

Genetické algoritmy patria do širšej skupiny evolučných algoritmov, kam sa zaraďujú aj ďalšie prístupy, napríklad genetické programovanie alebo evolučné programovanie. V porovnaní s inými metódami je pri genetických algoritmoch kladený dôraz najmä na prácu s populáciou riešení a na využitie operátora kríženia, prostredníctvom ktorého sa kombinujú vlastnosti viacerých riešení. Práve tento spôsob vytvárania nových jedincov umožňuje efektívne prehľadávať rozsiahly priestor riešení a hľadať kvalitné výsledky aj pri úlohách, ktoré sú z výpočtového hľadiska náročné [11], [12], [13].

Aby bolo možné genetický algoritmus efektívne použiť, je potrebné najskôr určiť jeho základné prvky a spôsob reprezentácie riešenia. Na rozdiel od tradičných optimalizačných metód, ktoré pracujú len s jedným riešením a to postupne upravujú, genetický algoritmus pracuje s celou populáciou kandidátnych riešení. Každý jedinec v tejto populácii predstavuje jedno možné riešenie problému, ktoré je zapísané vo forme chromozómu.

4.1. Reprezentácia riešenia

Spôsob, akým je konkrétne riešenie problému prevedené do podoby chromozómu, sa označuje ako kódovanie. V klasických genetických algoritmoch sa chromozóm najčastejšie zapisuje ako binárny reťazec pevnej dĺžky, teda ako postupnosť núl a jednotiek. Jednotlivé pozície v tomto reťazci predstavujú gény. Každý gén pritom vyjadruje určitú vlastnosť alebo parameter riešenia.

Okrem binárneho kódovania sa v genetických algoritmoch využívajú aj ďalšie formy reprezentácie, pričom ich výber závisí od charakteru riešeného problému. Pri úlohách, kde je dôležité poradie prvkov, sa často používa permutačné kódovanie. Naopak, pri problémoch pracujúcich s číselnými hodnotami je vhodné hodnotové kódovanie. V tejto práci je v aplikačnej časti využité permutačné kódovanie, pretože pri optimalizácii zvozočných trás zohráva rozhodujúcu úlohu práve poradie navštevovaných stojísk [11], [12].

4.2. Populácia a jej význam

Populácia predstavuje súbor všetkých jedincov, s ktorými algoritmus v danej generácii pracuje. Jej veľkosť a spôsob vytvorenia majú významný vplyv na priebeh aj výslednú kvalitu riešenia. Ak je populácia príliš malá, algoritmus môže príliš rýchlo konvergovať k lokálnemu optimu. Naopak, pri veľmi veľkej populácii síce rastie šanca na nájdenie lepšieho riešenia, no zároveň sa zvyšuje výpočtová náročnosť. V praxi je preto potrebné hľadať primeraný kompromis medzi kvalitou riešenia a časom výpočtu.

Počiatočná populácia sa najčastejšie generuje náhodne. V niektorých prípadoch je však možné využiť aj heuristické postupy, ak sú o riešenom probléme dostupné doplňujúce poznatky. Aj v takom prípade je dôležité zachovať dostatočnú rozmanitosť populácie, pretože príliš vysoká podobnosť medzi jedincami môže obmedziť schopnosť algoritmu objavovať nové a kvalitnejšie riešenia [12].

4.3. Operátory genetického algoritmu

Po inicializácii populácie a vyhodnotení fitness jednotlivých jedincov nasleduje hlavná časť genetického algoritmu, teda aplikácia evolučných operátorov. Medzi základné operátory jednoduchého genetického algoritmu patria selekcia, kríženie a mutácia. Práve ich opakovaným využívaním dochádza k postupnému zlepšovaniu populácie a k hľadaniu kvalitnejších riešení [12].

4.3.1 Selekcia

Selekcia predstavuje mechanizmus, prostredníctvom ktorého sú z aktuálnej populácie vybrané riešenia určené na vytvorenie ďalšej generácie. Jej princíp vychádza z prirodzeného výberu, pričom cieľom je zvýhodniť jedincov s lepšou fitness hodnotou. Takýmto spôsobom sa zvyšuje pravdepodobnosť, že kvalitnejšie riešenia budú prenesené aj do ďalších generácií.

V genetických algoritmoch sa používa viacero spôsobov selekcie. Medzi najznámejšie patrí ruletová selekcia, turnajová selekcia a elitizmus.

Ruletová selekcia je pravdepodobnostná metóda, pri ktorej je každému jedincovi priradená pravdepodobnosť výberu úmerná jeho fitness hodnote. Jedinci s vyššou fitness tak majú väčšiu šancu na výber, no určitá pravdepodobnosť zostáva aj menej kvalitným riešeniam, čo pomáha zachovávať rozmanitosť populácie [12].

Turnajová selekcia funguje na princípe náhodného výberu malej skupiny jedincov, z ktorej je následne vybraný najlepší. Tento postup sa opakuje dovtedy, kým nie je vytvorený potrebný počet rodičov. Výhodou tejto metódy je jej jednoduchosť, nízka výpočtová náročnosť a možnosť regulovať selekčný tlak [11], [12].

Elitizmus sa zvyčajne používa ako doplnok k selekcii. Jeho podstatou je, že najlepší jedinec alebo niekoľko najlepších jedincov z aktuálnej generácie je bez zmeny prenesených do generácie nasledujúcej. Tým sa zabezpečuje, že doteraz najlepšie nájdené riešenie nebude počas evolúcie stratené. V literatúre sa elitizmus často uvádza ako prvok, ktorý môže zlepšiť stabilitu aj výkonnosť genetického algoritmu [11].

4.3.2 Kríženie

Kríženie predstavuje operátor, prostredníctvom ktorého sa z dvoch rodičovských riešení vytvárajú nové riešenia. Jeho úlohou je kombinovať vlastnosti vybraných jedincov tak, aby mohli v ďalšej generácii vzniknúť kvalitnejší potomkovia. V genetických algoritmoch sa považuje za dôležitý mechanizmus, pretože umožňuje prenášanie a spájanie vhodných častí riešení.

Pri genetických algoritmoch možno použiť viacero spôsobov kríženia, pričom ich konkrétny výber závisí od typu kódovania a charakteru riešeného problému. Medzi základné patrí jednobodové kríženie, dvojbodové kríženie a uniformné kríženie.

Jednobodové kríženie patrí medzi najjednoduchšie formy. Na chromozóme sa náhodne určí jeden bod a časti za týmto bodom sa medzi rodičmi navzájom vymenia. Výsledkom sú dvaja noví potomkovia, ktorí obsahujú kombináciu vlastností oboch rodičov.

Dvojbodové kríženie funguje podobne, avšak namiesto jedného bodu sa určia dva body. Medzi nimi sa následne vymení určitý úsek chromozómu, čím vznikajú nové kombinácie génov.

Uniformné kríženie je založené na tom, že pre každú pozíciu chromozómu sa samostatne rozhoduje, od ktorého rodiča bude konkrétny gén prevzatý. Tento spôsob umožňuje vytvárať rozmanitejšie kombinácie riešení než jednoduchšie typy kríženia [10], [11].

Pri permutačnom kódovaní, ktoré je využité aj v tejto práci, však nie je možné bežné typy kríženia použiť priamo, pretože by mohlo dôjsť k vzniku neplatných riešení, napríklad k opakovaniu alebo vynechaniu niektorých zastávok. Z tohto dôvodu sa pri tomto type reprezentácie používajú špeciálne operátory určené pre permutácie, medzi ktoré patrí napríklad čiastočne párované kríženie (Partially Matched Crossover – PMX) [11], [12].

4.3.3 Mutácia

Mutácia predstavuje operátor, ktorý do genetického algoritmu vnáša náhodnosť a pomáha udržiavať rozmanitosť populácie. Jej úlohou je zabrániť tomu, aby sa populácia príliš rýchlo zjednotila a stratila schopnosť objavovať nové riešenia. Zvyčajne sa aplikuje s nízkou pravdepodobnosťou a spočíva v malej náhodnej zmene chromozómu.

Konkrétna forma mutácie závisí od typu použitého kódovania. Pri binárnom kódovaní ide najčastejšie o zmenu hodnoty génu z 0 na 1 alebo naopak. Pri permutačnom kódovaní, ktoré je využité aj v tejto práci, môže mutácia spočívať napríklad vo výmene dvoch prvkov v poradí alebo v inej malej úprave usporiadania zastávok.

Význam mutácie spočíva najmä v tom, že dopĺňa proces selekcie a kríženia. Hoci tieto operátory umožňujú vytvárať nové riešenia z už existujúcich jedincov, môže sa stať, že sa niektoré užitočné vlastnosti v populácii postupne stratia. Mutácia preto zabezpečuje, aby si algoritmus zachoval schopnosť preskúmať aj nové oblasti priestoru riešení a nezostal predčasne uviaznutý v lokálnom optime [12].

4.4. Genetický algoritmus pri riešení zvozu odpadu

Zvoz komunálneho odpadu predstavuje zložitú optimalizačnú úlohu, ktorú možno zaradiť do skupiny problémov smerovania vozidiel. Cieľom je navrhnúť také trasy zberových vozidiel, aby boli obslužené všetky stojiská pri čo najnižších nákladoch. V podmienkach tejto práce sa pritom neuvažuje len s prejdenu vzdialenosťou, ale aj s environmentálnym dopadom zberu. Keďže pri väčšom počte stojísk veľmi rýchlo rastie počet možných usporiadaní trás, použitie exaktných metód je pri reálnych úlohách obmedzené. Z tohto dôvodu bol na riešenie problému zvolený genetický algoritmus.

V navrhnutom prístupe je použitý genetický algoritmus s permutačným kódovaním, pri ktorom každý jedinec predstavuje konkrétne poradie návštevy stojísk odpadu. Samotný priebeh algoritmu pozostáva z niekoľkých základných krokov.

V prvom kroku je vytvorená počiatočná populácia, ktorá obsahuje náhodne vygenerované možné riešenia. Každý jedinec je reprezentovaný ako permutácia všetkých stojísk, pričom konkrétne rozdelenie na jednotlivé trasy vozidiel je následne určené s ohľadom na kapacitné obmedzenie.

Nasleduje vyhodnotenie fitness funkcie, teda kvality jednotlivých riešení. V závislosti od zvoleného modelu sa hodnotí buď celková prejdená vzdialenosť, alebo emisný náklad trasy. Fitness funkcia tak určuje, ktoré riešenia sú z hľadiska optimalizačného cieľa výhodnejšie.

V ďalšom kroku sa vykonáva selekcia, pri ktorej sa z populácie vyberajú rodičovské riešenia pre tvorbu novej generácie. V tejto práci sa používa turnajová selekcia doplnená o elitizmus, aby sa zachovali najlepšie riešenia aj v nasledujúcich generáciách.

Po selekcii nasleduje kríženie. Keďže riešenia sú reprezentované permutáciou stojísk, nie je možné použiť bežné typy kríženia bez rizika vzniku neplatného riešenia. Z tohto dôvodu sa využíva operátor Order Crossover (OX), ktorý zachováva platnosť permutácie a zároveň umožňuje kombinovať časti rodičovských riešení.

Ďalším krokom je mutácia, ktorá sa aplikuje s nízkou pravdepodobnosťou. Pri permutačnom kódovaní môže mať podobu výmeny dvoch stojísk alebo zmeny poradia určitého úseku trasy. Jej význam spočíva najmä v tom, že pomáha udržiavať rozmanitosť populácie a znižuje riziko predčasnej konverencie.

Po vykonaní selekcie, kríženia a mutácie je vytvorená nová generácia riešení. Tento proces sa opakuje dovtedy, kým nie je splnená ukončovacia podmienka, napríklad dosiahnutie stanoveného počtu generácií alebo zastavenie zlepšovania najlepšieho riešenia.

Výsledkom algoritmu je najlepšie nájdené riešenie, ktoré predstavuje poradie obsluhy jednotlivých stojísk pri rešpektovaní podmienok modelu. Takto navrhnutý postup umožňuje hľadať riešenia, ktoré sú z prevádzkového aj environmentálneho hľadiska vhodné a ktoré možno následne porovnať v rámci modelov GA-CVRP a GA-PRP.

Teoretické východiská uvedené v tejto kapitole vytvárajú základ pre praktickú časť práce, v ktorej bude genetický algoritmus aplikovaný na konkrétne dáta z mestskej časti Ružinov. Následne budú vyhodnotené dosiahnuté výsledky a porovnané z hľadiska prejdenej vzdialenosti aj environmentálnej záťaže.

5. Návrh a implementácia optimalizačného modelu

Praktická časť práce je zameraná na návrh a implementáciu optimalizačného postupu založeného na genetickom algoritme, ktorý je aplikovaný na modely kapacitného smerovania vozidiel (CVRP) a smerovania vozidiel s ohľadom na znečistenie (PRP).

Ako riešená oblasť bola zvolená mestská časť Ružinov v Bratislave, pre ktorú boli identifikované jednotlivé stojiská odpadu. Tieto stojiská v ďalšej analýze vystupujú ako uzly dopravnej siete.

Cieľom praktickej časti je na základe reálnych priestorových dát navrhnúť také trasy pre obmedzený počet vozidiel, aby boli obslužené všetky stojiská pri rešpektovaní kapacitných obmedzení a zároveň pri minimalizácii zvoleného optimalizačného kritéria. V prípade modelu CVRP ide o minimalizáciu celkovej prejdenej vzdialenosti, zatiaľ čo v prípade modelu PRP ide o minimalizáciu emisného nákladu.

Keďže modely CVRP a PRP patria medzi výpočtovo náročné kombinatorické optimalizačné úlohy, pri väčšom počte uzlov nie je ich presné riešenie exaktnými metódami v prijateľnom čase prakticky realizovateľné. Z tohto dôvodu bol v práci zvolený metaheuristický prístup, konkrétne genetický algoritmus. Ten prostredníctvom operátorov, ako sú selekcia, kríženie a mutácia, postupne prehľadáva priestor riešení a smeruje k nájdeniu kvalitného riešenia.

V rámci tejto kapitoly sú najskôr predstavené použité dáta a spôsob ich spracovania v programovacom jazyku Python. Následne je opísaná tvorba vzdialenostnej matice, formulácia optimalizačného problému a samotný návrh riešenia pomocou genetického algoritmu. Záver kapitoly je venovaný implementácii modelu, prezentácii dosiahnutých výsledkov a ich interpretácii v kontexte riešeného problému.

5.1. Popis dát

5.1.1 *OpenStreetMap a Overpass API ako zdroj dát*

OpenStreetMap (OSM) je globálna kolaboratívna geografická databáza dostupná pod otvorenou licenciou Open Database License (ODbL). Pre Bratislavu obsahuje tisíce zaznačených prvkov vrátane kontajnerových stojísk, zberných miest triedeného odpadu. Tieto prvky sú označované štandardizovanými kľúčmi:

- `amenity=waste_disposal` – zberné miesta zmesového a komunálneho odpadu

- `amenity=recycling` – zberné miesta triedeného odpadu (papier, plast, sklo)

Overpass API je webová služba umožňujúca dotazovanie OSM databázy pomocou Overpass Query Language (Overpass QL). Dotazy možno skladat' na webe `overpass-turbo.eu` alebo volať priamo z Pythonu cez knižnicu `requests` API a umožňuje stiahnutie výsledkov vo formáte JSON.

Pre účely tejto diplomovej práce bol zvolený OpenStreetMap ako primárny zdroj z dôvodu okamžitej dostupnosti a dostatočnej pokrytosti bratislavských stojísk [14], [15].

5.1.2 Získavanie súradníc stojísk

Teraz je možné ukázať, ako možno predstavené možnosti a zdroje dát preniesť do praxe pomocou dopytu v jazyku Overpass QL. Použitý dopyt má nasledujúcu podobu:

```
[out:json][timeout:180];      {{geocodeArea:Ružinov,Bratislava}}-
>.searchArea;


(nwr(area.searchArea)["amenity"]="recycling");
nwr(area.searchArea)["amenity"]="waste_disposal"](around.recycling
:50); );

out geom meta 50;
```

Tento Overpass QL dotaz je určený na vyhľadávanie prvkov z OpenStreetMap v mestskej časti Ružinov v Bratislave. Na začiatku sa pomocou funkcie `{{geocodeArea:Ružinov,Bratislava}}` prevedie názov lokality na plochu, ktorá sa uloží do premennej `searchArea`. Následne sa v zjednotení vykonajú dva čiastkové dopyty. Prvý vyberie všetky uzly, cesty a relácie (`nwr`) v rámci tejto plochy, ktoré majú tag `amenity=recycling`, teda miesta určené na triedený zber alebo recykláciu. Druhý dopyt vyberie prvky s tagom `amenity=waste_disposal`, teda kontajnery na zmesový odpad, ktoré sa nachádzajú do 50 metrov od už nájdených recyklačných miest. Túto podmienku zabezpečuje filter (`around.recycling:50`), pričom `recycling` odkazuje na množinu prvkov získanú v prvom dopyte. Oba typy prvkov sú vyhľadávané vo všetkých formách geometrickej reprezentácie OSM, teda ako uzly (`node`), línie (`way`) aj relácie (`relation`), čo je vyjadrené skratkou `nwr`.

Záverečný príkaz `out geom meta 50` zabezpečuje export prvých 50 výsledkov vrátane ich geometrie, teda súradníc, a metadát, konkrétne identifikátora OSM, čísla verzie

záznamu a časovej značky poslednej úpravy. Geometria predstavuje nevyhnutný predpoklad pre následný export dát do formátu GeoJSON a ich ďalšie spracovanie v prostredí Python.



Obr. 5.1 Rozloženie stojísk odpadu v Bratislave v mestskej časti Ružinov

Výsledok dopytu je znázornený na obrázku 5.1, kde modré kruhy reprezentujú stojiská odpadu v mestskej časti Ružinov. Exportované dáta vo formáte GeoJSON boli v ďalšom kroku načítané do prostredia Python, kde boli transformované do tabuľkovej štruktúry a použité ako vstup pre výpočet distančnej matice na reálnej cestnej sieti..

5.1.3 Transformácia do tabuľkovej štruktúry

Po získaní súradníc stojísk odpadu prostredníctvom Overpass API bolo potrebné exportované dáta previesť do štruktúrovanej tabuľkovej podoby vhodnej na ďalšie spracovanie. Surový výstup z Overpass Turbo je uložený vo formáte GeoJSON, ktorý predstavuje štandard pre kódovanie geografických dátových štruktúr založený na formáte JSON. Hoci je GeoJSON štandardným formátom v oblasti geografických informačných systémov, pre účely výpočtu distančnej matice a optimalizácie trás je výhodnejšie pracovať s tabuľkovým formátom CSV.

Predspracovanie bolo realizované v prostredí Python s využitím knižnice pandas, ktorá poskytuje nástroje pre manipuláciu a analýzu štruktúrovaných dát. Načítaný GeoJSON súbor obsahuje kolekciu geografických prvkov, pričom každý prvok predstavuje jedno stojisko odpadu. Z každého prvku boli extrahované nasledujúce atribúty: jedinečný identifikátor prvku v databáze OpenStreetMap (id), interný OSM identifikátor (osm_id),

typ zariadenia podľa OSM klasifikácie (amenity), kategória odpadu (waste) a geografické súradnice ako zemepisná dĺžka (lon) a zemepisná šírka (lat).

Extrahované záznamy boli usporiadané do dvojrozmiernej tabuľkovej štruktúry a následne uložené do súboru vo formáte CSV. Výsledná tabuľka obsahovala 50 záznamov, čo zodpovedá počtu stojísk exportovaných z Overpass Turbo pre mestskú časť Ružinov. Takto pripravená štruktúra tvorí vstupný základ pre výpočet distančnej matice na reálnej cestnej sieti, ktorý je popísaný v nasledujúcej podkapitole.

Distančná matica je štvorcová matica rozmeru $n \times n$, kde n predstavuje počet stojísk, pričom každý jej prvok vyjadruje vzdialenosť medzi dvojicou bodov. Na rozdiel od vzdialenosti vzdušnou čiarou, teda euklidovskej vzdialenosti, boli v tejto práci použité vzdialenosti vypočítané na základe reálnej cestnej siete, čo zodpovedá skutočným podmienkam pohybu zberného vozidla v mestskom prostredí.

Na výpočet distančnej matice bola využitá služba OpenRouteService (ORS), ktorá poskytuje rozhranie API pre smerovanie a výpočet vzdialeností na základe dát OpenStreetMap. Prístup k službe bol realizovaný prostredníctvom oficiálnej Python knižnice openrouteservice

Vstupom pre výpočet bol zoznam súradníc všetkých stojísk vo formáte [*zemepisná dĺžka, zemepisná šírka*], ktorý bol zostavený priamo z GeoJSON súboru. Výpočet bol nakonfigurovaný s profilom driving-car, ktorý modeluje pohyb osobným automobilom po verejnej cestnej sieti a zodpovedá charakteru pohybu zberného vozidla. Použitá metrika bola nastavená na vzdialenosť (distance).

Výsledkom volania ORS rozhrania je kompletná $n \times n$ matica vzdialeností, kde prvok na pozícii (i, j) vyjadruje dĺžku najkratšej cesty z i-teho stojiska do j-teho stojiska po cestnej sieti. Matica je všeobecne asymetrická, čiže vzdialenosť z bodu A do bodu B sa môže líšiť od vzdialenosti z bodu B do bodu A, čo je dôsledkom jednosmerných ulíc a obmedzení cestnej premávky v mestskom prostredí. Vypočítaná matica bola uložená do súboru CSV pre jej opakované použitie v ďalších fázach analýzy bez nutnosti opätovného volania API.

Služba OpenRouteService umožňuje výpočet maximálne 50×50 párov vzdialeností v rámci jedného dotazu[16]. Z tohto dôvodu bol počet analyzovaných stojísk obmedzený na 50. Táto metodika výpočtu distančnej matice na základe reálnej cestnej siete

predstavuje významné zlepšenie oproti prístupom využívajúcim euklidovskú vzdialenosť, keďže výsledky optimalizácie trás sú priamo aplikovateľné na skutočnú prevádzku zberného vozidla v podmienkach mestskej dopravnej siete Bratislavy.

5.1.4 Reálna cestná sieť vs. vzdušná vzdialenosť

V úlohách optimalizácie dopravných trás je voľba metriky vzdialenosti jedným zo zásadných metodologických rozhodnutí, ktoré priamo ovplyvňuje kvalitu a praktickú použiteľnosť výsledkov. V odbornej literatúre sa stretávame s dvoma základnými prístupmi a to s výpočtom vzdialenosti vzdušnou čiarou a výpočtom vzdialenosti na základe reálnej cestnej siete.

Vzdušná vzdialenosť (euklidovská vzdialenosť) predstavuje priamočiaru geometrickú vzdialenosť medzi dvoma bodmi definovanými ich zemepisnými súradnicami. Jej výpočet je matematicky jednoduchý, výpočtovo nenáročný a nevyžaduje žiadne externé dátové zdroje. Z týchto dôvodov sa vzdušná vzdialenosť často využíva v teoretických prácach alebo pri práci s dátami, kde nie sú dostupné podrobné informácie o dopravnej infraštruktúre. Zásadnou nevýhodou tohto prístupu je však skutočnosť, že vzdušná vzdialenosť systematicky podceňuje skutočnú prejdenu vzdialenosť, keďže nezohľadňuje geometriu cestnej siete, jednosmerné ulice, zákazové značky ani fyzické prekážky terénu. Na základe vykonaných výpočtov sa percentuálny rozdiel medzi vzdušnou a reálnou cestnou vzdialenosťou pohybuje v širokom intervale od približne 0,08 % až po 98,22 %, pričom priemerná hodnota dosahuje 36,93 %.

Vzdialenosť na reálnej cestnej sieti modeluje skutočný pohyb vozidla po existujúcej dopravnej infraštruktúre. Zohľadňuje smerovanie ulíc, jednosmerné obmedzenia, zákazy odbočenia, rýchlostné limity aj ďalšie atribúty cestnej siete. Výsledkom je vzdialenosť, prípadne čas jazdy, ktoré zodpovedajú podmienkam skutočnej prevádzky vozidla. Nevýhodou tohto prístupu je vyššia výpočtová náročnosť a závislosť od kvality a aktuálnosti podkladových mapových dát.

Pre potreby tejto práce bola zvolená vzdialenosť na reálnej cestnej sieti, a to z niekoľkých dôvodov. Predmetom optimalizácie sú trasy zberných vozidiel pohybujúcich sa v mestskom prostredí Bratislavy, kde je sieť ulíc charakteristická výraznou asymetriou vzdialenosti z bodu A do bodu B sa môže líšiť od vzdialenosti z bodu B do bodu A v dôsledku jednosmerných ulíc. Použitie vzdušnej vzdialenosti by v takomto prostredí viedlo k systematickému skresleniu optimalizačných výsledkov a k trasám, ktoré nie sú v praxi

realizovateľné alebo sú výrazne dlhšie než vypočítané optimum. Naopak, dištančná matica zostavená na základe reálnej cestnej siete prostredníctvom služby OpenRouteService zaručuje, že každý prvok matice zodpovedá skutočne prijateľnej a nameranej vzdialenosti, čím sa výstupy optimalizačného algoritmu stávajú priamo aplikovateľný v prevádzkovej praxi.

Rozdiel medzi oboma prístupmi ilustruje aj tabuľka nižšie, ktorá porovnáva hodnoty vzdušnej a cestnej vzdialenosti pre vybrané dvojice stojísk v mestskej časti Ružinov.

Dvojica stojísk	Vzdušná vzdialenosť (m)	Cestná vzdialenosť (m)	Rozdiel (%)
Stojisko 1 – Stojisko 2	1 899	3 048	+37,7 %
Stojisko 3 – Stojisko 4	268	1 451	+81,5 %
Stojisko 1 – Stojisko 4	3 073	3 723	+17,5 %

Tabuľka 5.1 Porovnanie vzdušnej a cestnej vzdialenosti

Z uvedených výsledkov je zrejmé, že medzi euklidovskou (vzdušnou) a reálnou cestnou vzdialenosťou existujú výrazné rozdiely, ktoré závisia od konkrétnej polohy stojísk a štruktúry cestnej siete. V niektorých prípadoch je rozdiel relatívne nízky (napr. 17,5 %), čo naznačuje, že komunikácie vedú pomerne priamo medzi bodmi. Naopak, pri iných dvojiciach stojísk dochádza k výraznému nárastu vzdialenosti (až 81,5 %), čo poukazuje na nutnosť obchádzok spôsobených prvkami, ako sú bloky budov, jednosmerné ulice alebo iné priestorové obmedzenia. Tieto zistenia potvrdzujú, že euklidovská vzdialenosť predstavuje len ideálnu aproximáciu a pre realistické modelovanie zberu odpadu je vhodnejšie používať vzdialenosti získané na základe reálnej cestnej siete.

5.1.5 Distančná matica z OpenStreetMap

Súradnice jednotlivých stojísk boli získané z databázy OpenStreetMap prostredníctvom služby Overpass API. Na ich základe bola následne pomocou modulu openrouteservice.distance_matrix zostavená distančná matica DIST. Táto matica obsahuje reálne cestné vzdialenosti medzi všetkými dvojicami bodov vrátane depa, ktoré je v modeli reprezentované indexom 0. Keďže výpočet vychádza z reálnej cestnej siete, matica je vo všeobecnosti asymetrická, teda vzdialenosť z bodu i do bodu j sa nemusí rovnať vzdialenosti z bodu j do bodu i . Takto vytvorená matica predstavuje vstupný údaj pre hodnotenie trás v optimalizačnom algoritme.


5.1.6 Simulácia hmotnosti odpadu

Keďže v rámci riešenej úlohy neboli k dispozícii presné údaje o aktuálnom hmotnostnom zaplnení 1100-litrových kontajnerov, bolo potrebné tieto hodnoty simulovať. Hmotnosť odpadu na jednotlivých stojiskách bola preto generovaná v intervale 100 až 300 kg. Zvolené rozmedzie bolo stanovené tak, aby zodpovedalo realistickému zaťaženiu kontajnerov a zároveň ostalo pod ich maximálnou konštrukčnou hmotnosťou, ktorá je 440 kg.

Takto určené hodnoty predstavujú zjednodušenú aproximáciu reálnych prevádzkových podmienok, keďže množstvo odpadu sa v praxi môže medzi jednotlivými stojiskami líšiť v závislosti od lokality, intenzity využívania alebo času od posledného vývozu. Simulácia hmotnosti odpadu bola preto v tejto práci použitá ako náhrada za chýbajúce reálne dáta a zároveň ako spôsob, ako zabezpečiť, aby model zohľadňoval kapacitné obmedzenia vozidiel a meniace sa zaťaženie počas trasy.

Vygenerované hodnoty zároveň predstavovali dopyt jednotlivých stojísk, teda parameter q_i , ktorý vstupoval do formulácie modelov CVRP aj PRP. Práve na základe týchto hodnôt bolo možné kontrolovať splnenie kapacitných obmedzení vozidiel a pri modeli PRP zároveň vyhodnocovať meniace sa zaťaženie vozidla na jednotlivých úsekoch trasy.

Rozdelenie simulovaných hodnôt odpadu na jednotlivých zastávkach je znázornené na obrázku 5.1. Z histogramu je zrejmé, že generované hodnoty pokrývajú celé zvolené rozmedzie a sú rozložené pomerne rovnomerne. Priemerná hodnota simulovaného odpadu dosiahla 203 kg a medián 202 kg, čo naznačuje, že rozdelenie dát nie je výrazne vychýlené.



Obr. 5.1. Histogram simulovaného množstva odpadu na jednotlivých stojiskách

Názorné priestorové rozmiestnenie simulovaných hodnôt je zobrazené na obrázku 5.2. Každému stojisku bola priradená konkrétna hodnota odpadu, ktorá je znázornená farebne aj číselne priamo v mape. Zobrazenie zároveň ukazuje polohu depa, z ktorého sú realizované zberové trasy. Takto pripravené vstupné údaje tvorili základ pre následné hodnotenie trás v rámci optimalizačného algoritmu.

6. Implementácia genetického algoritmu

6.1. Rozdelenie permutácie na trasy – `split_routes`

V implementácii genetického algoritmu je každé riešenie reprezentované ako permutácia stojísk, teda ako poradie, v akom majú byť jednotlivé body obslužené. Takto zapísaný chromozóm však ešte priamo nepredstavuje konkrétny súbor trás, pretože neobsahuje informáciu o tom, kde sa má jedna trasa ukončiť a kde sa má začať ďalšia. Z tohto dôvodu je potrebné permutáciu pred samotným vyhodnotením previesť na realizovateľné trasy, ktoré budú rešpektovať kapacitné obmedzenie vozidla. Na tento účel slúži funkcia `split_routes`, ktorá plní úlohu dekodéra riešenia.

```
def split_routes(order):
    routes = []
    current = []
    current_load = 0
    for customer in order:
        w = WASTE_KG[customer]
        if current and current_load + w > VEHICLE_CAPACITY_KG:
            routes.append(current)
            current = []
            current_load = 0
        current.append(customer)
        current_load += w
    if current:
        routes.append(current)
    return routes
```

Funkcia `split_routes` slúži ako dekodér, ktorý transformuje ľubovoľnú permutáciu zákazníkov, teda chromozóm, na konkrétne trasy zberového vozidla. Pracuje na princípe postupného priradovania zákazníkov do aktuálnej trasy, pričom priebežne sleduje celkové zaťaženie vozidla a rešpektuje maximálnu nosnosť `VEHICLE_CAPACITY_KG`. Ak by pridaním ďalšieho zákazníka došlo k prekročeniu kapacity, aktuálna trasa sa uzavrie a začne sa vytvárať nová. Výsledkom funkcie je zoznam trás, ktoré sú z hľadiska kapacity vozidla prípustné.

V rámci genetického algoritmu sa táto funkcia využíva na prevod chromozómu na realizovateľné riešenie. Výhodou tohto prístupu je, že neprípustné riešenia nie je potrebné dodatočne penalizovať, pretože každý jedinec je po dekódovaní automaticky prevedený do prípustnej podoby. Určitým obmedzením však zostáva, že rozdelenie stojísk medzi

jednotlivé trasy je určené výlučne poradím v permutácii, čo nemusí vždy viesť k najlepšiemu možnému rozdeleniu trás.

6.2. Výpočet emisného nákladu trasy – `route_emission`

Pri modeli GA-PRP nestačí hodnotiť trasu len podľa celkovej prejdenej vzdialenosti, ale je potrebné zohľadniť aj meniace sa zaťaženie vozidla počas zberu. Z tohto dôvodu bola do implementácie zaradená funkcia `route_emission`, ktorá pre každú trasu vypočíta emisný náklad na základe prejdenej vzdialenosti a aktuálnej hmotnosti vozidla na jednotlivých úsekoch.

```
def route_emission(route):
    current_load = 0
    em = DIST[DEPOT][route[0]] * VEHICLE_WEIGHT_KG

    for i in range(len(route) - 1):
        current_load += WASTE_KG[route[i]]
        em += DIST[route[i]][route[i + 1]] * (VEHICLE_WEIGHT_KG +
        current_load)

    current_load += WASTE_KG[route[-1]]
    em += DIST[route[-1]][DEPOT] * (VEHICLE_WEIGHT_KG +
    current_load)
    return em
```

Funkcia `route_emission` slúži na výpočet emisného nákladu jednej trasy na základe predpokladu, že environmentálna záťaž rastie s celkovou hmotnosťou vozidla. Emisný náklad na každom úseku je preto vyjadrený ako súčin prejdenej vzdialenosti a okamžitej hmotnosti vozidla, ktorá pozostáva z pohotovostnej hmotnosti vozidla a aktuálne naloženého odpadu.

Na začiatku sa započíta presun z depa k prvej zastávke, pri ktorom vozidlo ešte nepreváža žiadny odpad a zaťaženie tvorí len jeho vlastná hmotnosť. Pri každom ďalšom presune medzi zastávkami sa k aktuálnemu nákladu pripočíta odpad vyzbieraný na predchádzajúcej zastávke, takže emisný náklad sa postupne zvyšuje spolu s narastajúcou hmotnosťou vozidla. Po obslúžení poslednej zastávky sa rovnakým spôsobom vypočíta aj emisný náklad návratu do depa.

Takto definovaná funkcia predstavuje zjednodušený, ale výpočtovo efektívny spôsob vyjadrenia environmentálnej záťaže trasy. Jej výhodou je jednoduchá interpretácia

a nízka výpočtová náročnosť, čo je dôležité najmä pri opakovanom vyhodnocovaní veľkého počtu riešení v genetickom algoritme. Obmedzením tohto prístupu je, že nezohľadňuje všetky faktory ovplyvňujúce reálnu spotrebu paliva a emisie, napríklad charakter jazdy, sklon vozovky alebo aerodynamický odpor. Napriek tomu je takto zvolený model pre účely tejto práce postačujúci, pretože zachytáva základný vzťah medzi rastúcim zaťažením vozidla a rastúcim emisným nákladom.

V rámci genetického algoritmu je funkcia `route_emission` kľúčovou súčasťou hodnotenia riešenia, pretože umožňuje porovnávať jednotlivé trasy z hľadiska ich environmentálnej záťaže a smerovať evolučný proces k ekologickejšie priaznivejším riešeniam.

6.3. Výpočet celkovej prejdenej vzdialenosti trasy – `route_distance`

Pri modeli GA-CVRP je kvalita trasy hodnotená podľa celkovej prejdenej vzdialenosti. Na tento účel bola implementovaná funkcia `route_distance`, ktorá vypočíta dĺžku jednej trasy vrátane výjazdu z depa, presunov medzi jednotlivými zastávkami a návratu späť do depa.

```
def route_distance(route):
    d = DIST[DEPOT][route[0]]
    for i in range(len(route) - 1):
        d += DIST[route[i]][route[i + 1]]
    d += DIST[route[-1]][DEPOT]
    return d
```

Funkcia `route_distance` slúži na výpočet celkovej prejdenej vzdialenosti jednej trasy. Na začiatku sa započíta vzdialenosť medzi depom a prvou navštívenou zastávkou. Následne sa v cykle postupne sčítajú vzdialenosti medzi všetkými po sebe nasledujúcimi zastávkami v rámci danej trasy. Po obslúžení posledného stojiska sa k výslednej hodnote pripočíta ešte vzdialenosť potrebná na návrat vozidla späť do depa.

Na rozdiel od funkcie `route_emission`, ktorá zohľadňuje aj aktuálne zaťaženie vozidla, funkcia `route_distance` pracuje výlučne s dĺžkou trasy vyjadrenou prostredníctvom distančnej matice `DIST`. Vzdialenosť je tak určená len vzájomnou polohou jednotlivých bodov v cestnej sieti a nezávisí od množstva prepravovaného odpadu. Z tohto dôvodu je táto funkcia vhodná najmä pre model GA-CVRP, v ktorom je cieľom

minimalizovať celkovú prejdenu vzdialenosť bez priameho zohľadnenia environmentálnych faktorov.

V rámci genetického algoritmu predstavuje funkcia `route_distance` základ pre hodnotenie riešení v prípade vzdialenostného modelu. Umožňuje porovnávať jednotlivé trasy z hľadiska ich dĺžky a smerovať evolučný proces k riešeniam s nižším dopravným nákladom.

6.4. Genetické operátory

Chromozóm je v tejto práci reprezentovaný ako permutácia všetkých zákazníkov, napríklad vo forme `[3,7,1,5,2,...]`. Samotná permutácia však ešte priamo nepredstavuje konkrétne trasy vozidiel. Tie sa získajú až jej rozdelením pomocou funkcie `split_routes`, ktorá zabezpečí prevod chromozómu na realizovateľné trasy. Takto zvolená reprezentácia umožňuje, aby bolo každé riešenie po dekódovaní v súlade s kapacitným obmedzením vozidla.

6.4.1 Turnajová selekcia

Pri vytváraní novej generácie je potrebné z aktuálnej populácie vybrať rodičovské riešenia, ktoré budú vstupovať do procesu kríženia. V tejto práci bola na tento účel použitá turnajová selekcia, ktorá patrí medzi často využívané selekčné mechanizmy v genetických algoritmoch. Jej výhodou je jednoduchá implementácia, nízka výpočtová náročnosť a zároveň schopnosť zvýhodniť kvalitnejšie riešenia bez úplného vylúčenia náhodnosti.

```
def tournament_select(population):  
    candidates = random.sample(population, GA_TOURNAMENT_K)  
    return min(candidates, key=evaluate)
```

Funkcia `tournament_select` slúži na výber rodiča z populácie v každej generácii genetického algoritmu. Najskôr sa z aktuálnej populácie náhodne vyberie `GA_TOURNAMENT_K` jedincov. Následne sa z tejto podskupiny vyberie jedinec s najlepšou fitness hodnotou, teda ten, ktorý dosahuje najnižšiu hodnotu účelovej funkcie. Takto nastavený mechanizmus zabezpečuje, že kvalitnejšie riešenia majú vyššiu pravdepodobnosť výberu, no vďaka náhodnému zostaveniu turnaja nie sú úplne vylúčené ani ostatné chromozómy.

6.4.2 Kríženie – OX (Order Crossover)

Pri permutačnom kódovaní nie je možné použiť bežné typy kríženia bez rizika vzniku neplatného riešenia, pretože by mohlo dôjsť k opakovaniu alebo vynechaniu

niektorých stojísk. Z tohto dôvodu bol v implementácii genetického algoritmu použitý operátor Order Crossover (OX), ktorý je určený práve pre chromozómy reprezentované ako permutácie.

```
def ox_crossover(parent1, parent2):
    size = len(parent1)
    a, b = sorted(random.sample(range(size), 2))
    child = [None] * size
    child[a:b] = parent1[a:b]
    fill = [g for g in parent2 if g not in child]
    idx = 0
    for k in range(size):
        if child[k] is None:
            child[k] = fill[idx]
            idx += 1
    return child
```

Funkcia `ox_crossover` vytvára nového potomka kombináciou dvoch rodičovských chromozómov pri zachovaní platnej permutácie všetkých stojísk. Najskôr sa náhodne vyberú dva deliace body, ktoré určia súvislý úsek génov. Tento úsek sa následne prevezme z prvého rodiča a skopíruje sa do potomka na rovnaké pozície.

V ďalšom kroku sa z druhého rodiča v pôvodnom poradí preberajú tie gény, ktoré sa v potomkovi ešte nenachádzajú. Tieto gény sa potom postupne doplnia na zostávajúce voľné pozície. Takýmto spôsobom sa z prvého rodiča zachová vybraný úsek riešenia a zo druhého rodiča sa preberá relatívne poradie ostatných stojísk.

Výhodou operátora OX je, že pri permutačnom kódovaní vždy vytvára prípustné riešenie a zároveň umožňuje kombinovať užitočné časti oboch rodičovských chromozómov. Ide zároveň o výpočtovo nenáročný spôsob kríženia, ktorý je vhodný pre opakované použitie v genetickom algoritme. Určitým obmedzením môže byť to, že pri väčšom prevzatí úseku sa znižuje vplyv druhého rodiča, čo môže viesť k menšej rozmanitosti potomkov.

V rámci genetického algoritmu plní funkcia `ox_crossover` úlohu hlavného rekombinačného operátora, prostredníctvom ktorého sa spájajú vhodné časti rodičovských riešení a vytvárajú sa nové varianty trás s potenciálne nižším nákladom.

6.4.3 Mutácia – swap

Po vykonaní kríženia nasleduje mutácia, ktorej úlohou je zavádzať do populácie nové zmeny a podporovať rozmanitosť riešení. V tejto práci bola použitá swap mutácia,

ktorá patrí medzi najjednoduchšie a zároveň najčastejšie využívané mutačné operátory pri permutačnom kódovaní.

```
def swap_mutate(child):
    if random.random() < GA_MUTATION_RATE:
        i, j = random.sample(range(len(child)), 2)
        child[i], child[j] = child[j], child[i]
    return child
```

Funkcia `swap_mutate` realizuje mutáciu chromozómu s pravdepodobnosťou `GA_MUTATION_RATE`. Ak náhodne vygenerované číslo klesne pod túto hranicu, z chromozómu sa vyberú dve rôzne pozície a ich hodnoty sa navzájom zamenia. Takto vykonaná zmena nemení množinu navštívených stojísk, ale upravuje ich poradie, čím vzniká nová varianta riešenia.

Význam swap mutácie spočíva najmä v tom, že pomáha udržiavať rozmanitosť populácie a znižuje riziko predčasnej konvergenzie algoritmu. Zatiaľ čo kríženie kombinuje vlastnosti už existujúcich rodičovských riešení, mutácia umožňuje vytvárať aj také zmeny, ktoré by sa samotným krížením nemuseli objaviť. Tým sa zvyšuje schopnosť algoritmu preskúmať nové oblasti priestoru riešení a prípadne sa vyhnúť uviaznutiu v lokálnom optime. Výstupom funkcie je modifikovaný chromozóm, ktorý sa následne zaradí do novej populácie.

6.4.4 Hlavná evolučná slučka s elitizmom

Po definovaní jednotlivých genetických operátorov nasleduje hlavná evolučná slučka, v rámci ktorej prebieha samotný vývoj populácie počas genetického algoritmu. Práve v tejto časti sa opakovane vykonáva selekcia, kríženie, mutácia a aktualizácia najlepšieho doteraz nájdeného riešenia.

```
for gen in range(GA_GENERATIONS):
    new_population = [best_ind]
    while len(new_population) < GA_POP_SIZE:
        p1 = tournament_select(population)
        p2 = tournament_select(population)
        child = ox_crossover(p1, p2)
        child = swap_mutate(child)
        new_population.append(child)
    population = new_population

    gen_best = min(population, key=evaluate)
    if evaluate(gen_best) < evaluate(best_ind):
        best_ind = gen_best
```

```

    history.append(evaluate(best_ind))
    if gen % 100 == 0:
        print(f" [{label}] gen {gen:4d} | fitness = {evaluate(best_ind):.2f}")
    print(f" [{label}] hotovo | fitness = {evaluate(best_ind):.2f}")
    return split_routes(best_ind), history

```

Jadrom genetického algoritmu je evolučná slučka, ktorá sa vykonáva počas vopred stanoveného počtu generácií `GA_GENERATIONS`. V každej generácii sa vytvára nová populácia na základe populácie predchádzajúcej. Na začiatku každej iterácie sa do novej populácie bez zmeny prenesie najlepší doteraz nájdený jedinec `best_ind`. Tým sa realizuje elitizmus, ktorého úlohou je zabezpečiť, aby sa najkvalitnejšie riešenie počas vývoja populácie nestratilo.

Zvyšok novej populácie sa postupne dopĺňa vytváraním potomkov. Najskôr sa pomocou turnajovej selekcie vyberú dvaja rodičia z aktuálnej populácie. Následne sa na nich aplikuje operátor kríženia `ox_crossover` a výsledný potomok sa ešte môže upraviť pomocou mutácie `swap_mutate`. Takto vytvorený jedinec sa zaradi do novej populácie. Tento proces sa opakuje dovtedy, kým populácia nedosiahne požadovanú veľkosť `GA_POP_SIZE`.

Po vytvorení novej generácie sa v nej identifikuje najlepší jedinec `gen_best`, ktorý sa následne porovná s globálne najlepším riešením `best_ind`. Ak je nové riešenie kvalitnejšie, `best_ind` sa aktualizuje. Zároveň sa hodnota fitness najlepšieho jedinca v každej generácii ukladá do zoznamu `history`, čo umožňuje sledovať priebeh konvergenzie algoritmu a neskôr ho analyzovať aj graficky.

Takto navrhnutá evolučná schéma zabezpečuje postupné zlepšovanie populácie v priebehu generácií. Výhodou použitia elitizmu je, že hodnota najlepšieho nájdeného riešenia sa počas behu algoritmu nemôže zhoršiť. Výsledkom funkcie je najlepšie nájdené riešenie po dekódovaní na konkrétne trasy a zároveň história vývoja fitness hodnoty počas celého priebehu optimalizácie.

Navrhnutá implementácia genetického algoritmu vytvára ucelený rámec pre riešenie úloh smerovania vozidiel v podmienkach zvozu komunálneho odpadu. Jednotlivé funkčné časti algoritmu zabezpečujú prevod chromozómu na realizovateľné trasy, vyhodnotenie kvality riešenia aj samotný evolučný proces vedúci k postupnému zlepšovaniu populácie. Vďaka oddeleniu účelových funkcií bolo možné rovnaký

implementačný základ využiť pri dvoch rozdielnych optimalizačných cieľoch, teda pri minimalizácii prejdenej vzdialenosti aj pri minimalizácii emisného nákladu. Takto navrhnutá štruktúra zároveň vytvára vhodný základ pre následné experimentálne overenie správania algoritmu a porovnanie dosiahnutých výsledkov.

7. Testovanie vhodnosti parametrov genetického algoritmu

Pred použitím genetického algoritmu v hlavných experimentoch bolo potrebné určiť vhodné nastavenie jeho parametrov. Keďže hodnoty parametrov, ako sú veľkosť populácie, počet generácií, pravdepodobnosť mutácie alebo veľkosť turnaja, môžu výrazne ovplyvniť kvalitu výsledného riešenia aj výpočtovú náročnosť algoritmu, ich voľba nemohla byť ponechaná na náhodný výber. Z tohto dôvodu bolo v ďalšej časti realizované testovanie viacerých kombinácií parametrov s cieľom zvoliť také nastavenie, ktoré bude poskytovať stabilné a kvalitné výsledky v prijateľnom výpočtovom čase.

Pred hlavnými experimentmi bolo potrebné overiť vhodnosť zvolených parametrov genetického algoritmu. Parametre ako veľkosť populácie, počet generácií, miera mutácie a veľkosť turnaja ovplyvňujú priebeh optimalizácie, kvalitu riešenia aj čas výpočtu. Z tohto dôvodu bolo realizované pilotné testovanie viacerých experimentálnych sád:

Sada A predstavovala základné nastavenie s parametrami POP_SIZE = 150, GENERATIONS = 1000, MUTATION_RATE = 0,02 a TOURNAMENT_K = 5. Obe varianty genetického algoritmu pri tomto nastavení dosiahli lepšie výsledky než referenčná heuristika.

Sada B bola zameraná na rýchlejší výpočet. Parametre boli nastavené na POP_SIZE = 50, GENERATIONS = 300, MUTATION_RATE = 0,10 a TOURNAMENT_K = 3. Hoci sa čas výpočtu výrazne skrátil, kvalita riešení sa zhoršila, najmä pri modeli GA-CVRP.

Sada C využívala nižšiu mieru mutácie a vyšší selekčný tlak (POP_SIZE = 150, GENERATIONS = 1000, MUTATION_RATE = 0,005, TOURNAMENT_K = 15). Na testovanej úlohe sa však toto nastavenie neukázalo ako najvýhodnejšie, keďže výsledky boli len mierne lepšie alebo porovnateľné s referenčnou heuristikou.

Sada D bola zameraná na vyššiu mutáciu (POP_SIZE = 150, GENERATIONS = 500, MUTATION_RATE = 0,20, TOURNAMENT_K = 5). Pri modeli GA-CVRP priniesla najlepšie výsledky zo všetkých testovaných sád, pričom celková vzdialenosť klesla na 54,87 km.

Sada E bola nastavená na POP_SIZE = 200, GENERATIONS = 500, MUTATION_RATE = 0,05 a TOURNAMENT_K = 2. Pri modeli GA-PRP dosiahla najlepšie výsledky,

konkrétne vzdialenosť 55,99 km a emisný náklad $0,3556 \times 10^9$ kg·m. Zároveň poskytla dobré výsledky aj pri modeli GA-CVRP.

Na základe výsledkov testovania bola pre hlavnú experimentálnu časť práce zvolená konfigurácia vychádzajúca zo Sady E, konkrétne GA_POP_SIZE=200, GA_GENERATIONS= 500, GA_MUTATION_RATE= 0,05 a GA_TOURNAMENT_K= 2. Táto voľba bola urobená na základe výsledkov dosiahnutých na riešenej úlohe a nie na základe všeobecných predpokladov o vplyve parametrov.

7.1. Finálna konfigurácia použitá v práci

Na základe pilotného ladenia bola pre hlavnú experimentálnu časť práce zvolená konfigurácia GA_POP_SIZE=200, GA_GENERATIONS=1500, GA_MUTATION_RATE = 0,05 a GA_TOURNAMENT_K=2. Táto voľba vychádza zo sady E, pričom počet generácií bol zvýšený tak, aby mal algoritmus dostatočný priestor na stabilizáciu riešení.

Okrem parametrov genetického algoritmu boli v práci fixované aj ďalšie modelové konštanty, konkrétne nosnosť vozidla VEHICLE_CAPACITY_KG=3000, pohotovostná hmotnosť vozidla VEHICLE_WEIGHT_KG=5000 a náhodný seed RANDOM_SEED= 42. Hodnota nosnosti 3000 kg bola zvolená ako zjednodušený modelový predpoklad reprezentujúci kapacitne obmedzené zberové vozidlo v mestských podmienkach. Pohotovostná hmotnosť vozidla 5000 kg bola použitá ako referenčná hodnota potrebná pre výpočet emisného nákladu v modeli PRP, keďže ten závisí od celkovej hmotnosti vozidla počas jazdy. Náhodný seed 42 bol nastavený z dôvodu reprodukovateľnosti výpočtov, aby bolo možné jednotlivé experimenty opakovane spúšťať za rovnakých vstupných podmienok. Tieto hodnoty boli ponechané nemenné vo všetkých scenároch, aby bolo možné rozdiely vo výsledkoch pripísať predovšetkým rozdielom medzi účelovými funkciami a konfiguráciami algoritmu, a nie odlišným vstupným podmienkam.

8. Porovnávací algoritmus Clarkovej-Wrightovej heuristiky

Pre účely vyhodnotenia kvality riešení dosiahnutých pomocou navrhnutého genetického algoritmu bola do experimentálnej časti práce zaradená aj referenčná metóda, konkrétne algoritmus Clarka-Wrighta. Tento algoritmus patrí medzi najznámejšie a najčastejšie používané konštruktívne heuristiky určené na riešenie problému smerovania vozidiel. Jeho zaradenie do práce bolo motivované najmä tým, že dokáže v krátkom výpočtovom čase poskytnúť prípustné a z praktického hľadiska použiteľné riešenie, ktoré môže slúžiť ako vhodný benchmark pre porovnanie s výsledkami genetického algoritmu [17].

Základná myšlienka Clarkeovho-Wrightovho algoritmu vychádza z konceptu úspory, ktorá vzniká spojením dvoch samostatných trás do jednej. V počiatočnej fáze je každému stojisku priradená samostatná trasa vedúca z depa k danému stojisku a späť. Následne sa pre každú dvojicu stojísk i a j vypočíta hodnota úspory s_{ij} , ktorá vyjadruje, o koľko by sa mohla skrátiť celková prejdená vzdialenosť, ak by boli obe stojiská obslužené v rámci jednej spoločnej trasy namiesto dvoch oddelených jázd. Hodnota úspory je definovaná vzťahom:

$$s_{ij} = d_{0i} + d_{0j} - d_{ij}$$

kde d_{0i} a d_{0j} predstavujú vzdialenosti z depa ku stojiskám i a j a d_{ij} je vzdialenosť medzi stojiskami, pričom $i, j \in N_0$.

Po výpočte všetkých hodnôt úspor algoritmus zoradí dvojice stojísk zostupne podľa ich veľkosti a postupne sa pokúša spájať príslušné trasy, pričom začína od dvojice s najvyššou úsporou. Spojenie dvoch trás sa vykoná len vtedy, ak výsledná trasa zostane kapacitne prípustná a neprekročí maximálnu nosnosť vozidla Q . Tento proces pokračuje dovtedy, kým už nie je možné vytvoriť ďalšie výhodné a prípustné spojenie.

V tejto práci je Clarkov-Wrightov algoritmus použitý ako referenčná metóda, voči ktorej sú porovnávané výsledky dosiahnuté pomocou genetického algoritmu pri modeloch CVRP a PRP. Takéto porovnanie umožňuje objektívnejšie posúdiť prínos metaheuristického prístupu oproti klasickej konštruktívnej heuristike, a to nielen z hľadiska kvality získaných riešení, ale aj z pohľadu výpočtovej náročnosti [17].

8.1 Implementácia Clarkovej-Wrightovej heuristiky

V praktickej časti bola Clarkova-Wrightova heuristika implementovaná vo forme funkcie `clarke_wright`, ktorá vychádza z klasického savings princípu a slúži na zostavenie kapacitne prípustných trás.

```
def clarke_wright():
    routes = [[c] for c in CUSTOMERS]
    savings = []

    for i in CUSTOMERS:
        for j in CUSTOMERS:
            if i < j:
                saving = DIST[DEPOT][i] + DIST[DEPOT][j] -
DIST[i][j]
                savings.append((saving, i, j))
    savings.sort(reverse=True)

    for saving, i, j in savings:
        route_i = next((r for r in routes if i in r), None)
        route_j = next((r for r in routes if j in r), None)

        if route_i is None or route_j is None:
            continue
        if route_i is route_j:
            continue
        if route_load(route_i) + route_load(route_j) >
VEHICLE_CAPACITY_KG:
            continue
        if route_i[-1] != i:
            route_i.reverse()
        if route_j[0] != j:
            route_j.reverse()
        merged = route_i + route_j
        routes = [r for r in routes if r is not route_i and r is
not route_j]
        routes.append(merged)

    return routes
```

Funkcia `clarke_wright` začína vytvorením najjednoduchšieho možného riešenia, v ktorom má každý zákazník vlastnú samostatnú trasu. Následne sa vypočíta hodnota úspory pre všetky dvojice zákazníkov a tieto dvojice sa zoradia od najvyššej úspory po najnižšiu. V ďalšom kroku sa algoritmus pokúša spájať trasy tých zákazníkov, pri ktorých je očakávaná úspora najväčšia.

Pred samotným spojením sa vždy kontroluje, či obaja zákazníci nepatria už do tej istej trasy a či spojením nedôjde k prekročeniu kapacity vozidla. Ak sú podmienky splnené, príslušné trasy sa upravujú tak, aby bolo možné ich korektné spojenie, a následne sa zlúčia do jednej novej trasy. Tento postup sa opakuje až dovtedy, kým už nie je možné vykonať ďalšie prípustné spojenie.

Výhodou Clarkovej-Wrightovej heuristiky je jej jednoduchosť, rýchlosť a nízka výpočtová náročnosť. Na rozdiel od genetického algoritmu nepracuje s populáciou riešení ani s evolučnými operátormi, ale vytvára riešenie konštruktívnym spôsobom. Jej obmedzením však je, že je primárne orientovaná na minimalizáciu vzdialenosti a nezohľadňuje priamo meniace sa zaťaženie vozidla počas trasy. Z tohto dôvodu je v tejto práci využitá najmä ako porovnávací metóda, nie ako hlavný nástroj riešenia emisne orientovaného modelu PRP.

V nasledujúcej kapitole budú výsledky Clarkovej-Wrightovej heuristiky porovnané s výsledkami genetického algoritmu z hľadiska celkovej prejdenej vzdialenosti aj emisného nákladu, aby bolo možné posúdiť prínos navrhnutého metaheuristického prístupu.

9. Nastavenie experimentov

V nadväznosti na kapitolu 6, v ktorej boli predstavené jednotlivé komponenty optimalizačného nástroja, nasleduje experimentálne overenie jeho výkonnosti. Cieľom tejto časti je jasne definovať podmienky, za ktorých boli jednotlivé algoritmy testované, aby bolo možné výsledky správne interpretovať a v prípade potreby aj zopakovať. Experimentálne nastavenie zahŕňa fixné parametre modelu, konfiguráciu genetického algoritmu, charakteristiku testovacej úlohy a porovnávané prístupy.

Základné parametre modelu boli zvolené tak, aby zodpovedali technickým vlastnostiam zberových vozidiel a charakteru komunálneho odpadu. Maximálna nosnosť jedného vozidla bola stanovená na 3 000 kg, čo predstavuje modelové kapacitné obmedzenie pri zbere v mestskom prostredí. Pri výpočte emisného nákladu bola zároveň zohľadnená aj pohotovostná hmotnosť prázdneho vozidla, ktorá bola fixovaná na 5 000 kg.

Genetický algoritmus bol nastavený tak, aby bola zachovaná dostatočná diverzita populácie pri prijateľnom výpočtovom čase. Veľkosť populácie bola stanovená na 200 jedincov a počet generácií na 1 500. Selekcia rodičov prebiehala turnajovým výberom s veľkosťou turnaja $GA_TOURNAMENT_K = 2$, čo predstavuje mierny selekčný tlak a zároveň znižuje riziko predčasnej konverencie. Na kríženie chromozómov bol použitý operátor Order Crossover (OX), ktorý rešpektuje permutačný charakter riešenia, a mutácia bola realizovaná pomocou swap operátora. Súčasťou evolučnej schémy bol aj elitizmus, vďaka ktorému sa najlepší jedinec z predchádzajúcej generácie prenáša do novej populácie bez zmeny.

Keďže genetický algoritmus má stochastický charakter, každá testovaná konfigurácia bola spustená desaťkrát. Takýto postup umožňuje hodnotiť nielen najlepší dosiahnutý výsledok, ale aj priemernú výkonnosť a variabilitu riešení. V ďalšej časti sú preto výsledky vyhodnocované na základe najlepšieho behu, priemerných hodnôt a smerodajných odchýlok z desiatich opakovaní.

Testovacia úloha vychádza z reálnych geografických dát mestskej časti Bratislava-Ružinov a zahŕňa 49 zberných stojísk a jedno centrálné depo. Priestorové rozmiestnenie stojísk nie je rovnomerné. Väčšina bodov vytvára prirodzené zhluky zodpovedajúce hustej sídliskovej zástavbe, zatiaľ čo menšia časť sa nachádza v okrajových častiach územia. Táto

štruktúra je z hľadiska trasovania dôležitá, pretože umožňuje obsluhovať skupiny blízkych stojísk v rámci jednej trasy.

Celkové simulované množstvo odpadu dosiahlo 9 952 kg. Pri štyroch vozidlách s nosnosťou 3 000 kg predstavuje celková dostupná kapacita 12 000 kg, čo znamená priemerné využitie približne 83 %. Algoritmus tak nie je nútený vyťažovať každé vozidlo až na hranicu jeho kapacity a má určitú voľnosť pri rozdelení stojísk medzi jednotlivé trasy.

V rámci experimentov boli porovnávané tri prístupy. Prvým bola Clarkova-Wrightova heuristika, ktorá slúžila ako referenčné riešenie. Ide o deterministickú konštruktívnu metódu, ktorá v krátkom čase vytvorí prípustné riešenie zamerané na minimalizáciu celkovej prejdenej vzdialenosti. Druhým prístupom bol genetický algoritmus optimalizujúci vzdialenosť, označovaný ako GA-CVRP. Jeho účelová funkcia bola definovaná ako súčet vzdialeností prejdenej všetkými vozidlami. Tretím prístupom bol genetický algoritmus optimalizujúci emisný náklad, označovaný ako GA-PRP. V tomto prípade bola fitness funkcia založená na emisnom modeli, v ktorom je náklad každej trasy určený ako súčet súčinov dĺžok jednotlivých úsekov a aktuálnej hmotnosti vozidla. Tým sa zohľadňuje skutočnosť, že s rastúcim zaťažením vozidla rastie aj environmentálna záťaž prepravy. Všetky tri prístupy boli testované na rovnakej inštancii s identickými vstupnými dátami. Pri genetických algoritmoch bolo zároveň použitých desať nezávislých behov, čo umožňuje objektívne porovnanie výsledkov a ich následné štatistické vyhodnotenie.

9.1. Výsledky experimentu

V tejto kapitole sú prezentované výsledky troch porovnávaných prístupov, konkrétne Clarkovej-Wrightovej heuristiky, genetického algoritmu optimalizujúceho vzdialenosť (GA-CVRP) a genetického algoritmu optimalizujúceho emisný náklad (GA-PRP). Cieľom tejto časti je nielen uviesť dosiahnuté numerické výsledky, ale aj interpretovať rozdiely medzi jednotlivými metódami z hľadiska kvality riešenia, stability správania algoritmu a štruktúry vytvorených trás. Súhrnné porovnanie hlavných ukazovateľov je uvedené v tabuľke č. 1, detailný rozpis trás najlepších riešení v tabuľke č. 2 a grafické znázornenie správania algoritmov a výsledných trás je doplnené na obrázkoch 9.1 až 9.3.

9.2. Porovnanie metód

Základné porovnanie výkonnosti jednotlivých algoritmov je uvedené v tabuľke 9.1. Ako referenčné riešenie bola použitá Clarkova-Wrightova heuristika, ktorá dosiahla

celkovú vzdialenosť 69,97 km a emisný náklad $0,4396 \times 10^9$ kg·m pri zanedbateľnom výpočtovom čase. Toto riešenie predstavuje východiskovú úroveň kvality, ktorú bolo možné dosiahnuť jednoduchou konštruktívnou metódou.

V porovnaní s referenčnou heuristikou dosiahol genetický algoritmus optimalizujúci vzdialenosť (GA-CVRP) výrazne lepšie výsledky. Najlepší beh viedol k zníženiu vzdialenosti na 53,48 km a emisného nákladu na $0,3340 \times 10^9$ kg·m. Zároveň sa ukázalo, že aj pri optimalizácii zameranej len na vzdialenosť dochádza k sekundárnemu zlepšeniu emisného ukazovateľa.

Ešte lepší výsledok bol dosiahnutý modelom GA-PRP, ktorý v najlepšom behu dosiahol vzdialenosť 52,83 km a emisný náklad $0,3293 \times 10^9$ kg·m. Z porovnania vyplýva, že emisne orientovaný model bol schopný nájsť riešenie, ktoré bolo nielen environmentálne priaznivejšie, ale zároveň aj o niečo kratšie než najlepšie riešenie GA-CVRP.

Pri pohľade na priemerné výsledky z desiatich behov sa však ukazuje rozdiel v stabilite oboch genetických prístupov. GA-CVRP dosahoval priemernú vzdialenosť $58,67 \pm 2,96$ km a emisný náklad $0,3748 \pm 0,0198 \times 10^9$ kg·m, zatiaľ čo pri GA-PRP bola zaznamenaná vyššia variabilita, keďže priemerná vzdialenosť dosiahla $59,92 \pm 5,44$ km a priemerný emisný náklad $0,3751 \pm 0,0335 \times 10^9$ kg·m. To naznačuje, že GA-CVRP bol pri opakovaných behoch stabilnejší, zatiaľ čo GA-PRP bol citlivejší na konkrétny priebeh evolúcie.

Rozdiel sa prejavil aj vo výpočtovom čase. GA-PRP bol časovo náročnejší než GA-CVRP, čo súvisí so zložitejšou fitness funkciou, pri ktorej sa priebežne zohľadňuje meniace sa zaťaženie vozidla na jednotlivých úsekoch trasy.


Metóda	Vzdialenosť [km]	Emisný náklad [$\times 10^9$ kg·m]	Čas výpočtu [s]
Clarke-Wright	69,97	0,4396	0,005
GA-CVRP (najlepší)	53,48	0,3340	50,65
GA-CVRP (priemer $\pm$ std)	$58,67 \pm 2,96$	$0,3748 \pm 0,0198$	–
GA-PRP (najlepší)	52,83	0,3293	72,67
GA-PRP (priemer $\pm$ std)	$59,92 \pm 5,44$	$0,3751 \pm 0,0335$	–

Tabuľka 9.1 Porovnanie výkonnosti jednotlivých algoritmov

Z hľadiska výpočtového času bol Clarkov-Wrightov algoritmus jednoznačne najrýchlejší, čo je prirodzený dôsledok jeho konštruktívneho charakteru. Genetické algoritmy boli časovo náročnejšie, pričom GA-PRP vyžadoval dlhší čas než GA-CVRP. Dôvodom je zložitejšia fitness funkcia, ktorá pri každom vyhodnotení zohľadňuje aj meniace sa zaťaženie vozidla na jednotlivých úsekoch trasy. Napriek tomu možno konštatovať, že dodatočný výpočtový čas bol vyvážený vyššou kvalitou dosiahnutých riešení.

Na základe uvedených výsledkov možno konštatovať, že genetický algoritmus v oboch variantoch prekonal referenčnú Clarkovu-Wrightovu heuristiku. Model GA-CVRP sa ukázal ako stabilnejší pri opakovaných behoch, zatiaľ čo model GA-PRP dosiahol najlepšie individuálne riešenie z hľadiska vzdialenosti aj emisného nákladu. Výsledky tak potvrdzujú, že zohľadnenie environmentálneho kritéria môže viesť k ďalšiemu zlepšeniu kvality riešenia, aj keď za cenu vyššej variability a dlhšieho výpočtového času.

Na doplnenie súhrnných výsledkov je na obrázku nižšie znázornený priebeh konvergenzie genetického algoritmu pri oboch optimalizačných variantoch. Z grafu je možné sledovať, ako sa v priebehu generácií postupne zlepšovala hodnota fitness funkcie.



Obr. 9.1 Konvergenzia genetického algoritmu pri modeloch CVRP a PRP

Z priebehu konvergence je zrejmé, že najvýraznejšie zlepšenie nastáva v počiatočných generáciách, zatiaľ čo v neskoršej fáze sa vývoj riešenia postupne stabilizuje. Model GA-CVRP dosahuje plynulejšiu a stabilnejšiu konvergenciu, zatiaľ čo pri GA-PRP je priebeh kolísavejší, čo zodpovedá vyššej variabilite pozorovanej aj pri priemerných výsledkoch.

9.3. Detailná analýza najlepších riešení

Podrobnejší pohľad na najlepšie nájdené riešenia poskytuje tabuľka č. 2, v ktorej je uvedený detailný rozpis trás, zaťaženia jednotlivých vozidiel a dĺžky trás pri všetkých porovnávaných prístupoch.

Z tabuľky 9.2. vyplýva, že všetky tri metódy vytvorili riešenie pozostávajúce zo štyroch trás. Pri Clarkovej-Wrightovej heuristike boli dve trasy výrazne dlhšie a zároveň silne zaťažené, zatiaľ čo zvyšné dve trasy mali kratší charakter. Naopak, pri genetických algoritmoch bolo možné pozorovať vyrovnanejšie rozdelenie trás aj lepšie priestorové rozloženie obsluhovaných stojísk.

V prípade GA-CVRP sa prejavila snaha minimalizovať celkovú dĺžku trás, čo viedlo ku kompaktniejšiemu usporiadaniu a k obmedzeniu zbytočných presunov medzi vzdialenejšími časťami územia. Pri GA-PRP sa okrem samotnej dĺžky trás prejavilo aj iné poradie obsluhy stojísk, ktoré lepšie zohľadňovalo zaťaženie vozidla počas jazdy. Rozdiel medzi oboma genetickými prístupmi sa tak neprejavil len v hodnote účelovej funkcie, ale aj v samotnej organizácii trás.


Algoritmus	Vozidlo	Zaťaženie [kg]	Dĺžka [km]	Poradie zákazníkov (depo → ... → depo)
Clarke-Wright	1	2 955	22,53	38 → 35 → 39 → 14 → 30 → 47 → 3 → 4 → 17 → 18 → 5 → 41 → 36 → 40 → 23
	2	2 983	23,91	24 → 25 → 20 → 26 → 2 → 15 → 27 → 16 → 1 → 37 → 22 → 6 → 48
	3	2 065	15,45	12 → 7 → 42 → 31 → 34 → 33 → 32 → 21 → 19 → 46 → 29
	4	1 949	8,07	28 → 8 → 49 → 45 → 13 → 43 → 44 → 10 → 9 → 11
GA-CVRP	1	2 870	18,86	15 → 2 → 46 → 42 → 19 → 37 → 48 → 6 → 26 → 27 → 34 → 32 → 31 → 12
	2	2 892	17,07	10 → 29 → 47 → 4 → 3 → 18 → 17 → 5 → 36 → 35 → 23 → 1 → 16 → 22 → 7 → 11

Algoritmus	Vozidlo	Zaťaženie [kg]	Dĺžka [km]	Poradie zákazníkov (depo → ... → depo)
	3	2 922	13,74	28 → 43 → 33 → 40 → 39 → 30 → 41 → 14 → 38 → 20 → 24 → 25 → 21
	4	1 268	3,81	9 → 49 → 13 → 45 → 44 → 8
GA-PRP	1	2 999	16,50	26 → 27 → 2 → 15 → 7 → 6 → 48 → 33 → 34 → 32 → 31 → 12 → 28 → 10 → 11
	2	2 889	15,65	9 → 29 → 46 → 42 → 19 → 20 → 14 → 40 → 4 → 3 → 18 → 17 → 23 → 1 → 37
	3	2 854	16,42	22 → 16 → 35 → 36 → 5 → 47 → 24 → 25 → 38 → 41 → 30 → 39 → 21
	4	1 210	4,25	8 → 49 → 13 → 43 → 44 → 45


Tabuľka 9.2 Detailný rozpis trás najlepších riešení

Z tabuľky 9.2 zároveň vyplýva, že všetky porovnávané metódy vytvorili riešenie pozostávajúce zo štyroch trás. Pri Clark-Wrightovej heuristike boli dve trasy výrazne dlhšie a kapacitne viac zaťažené, zatiaľ čo zvyšné dve trasy mali kratší charakter. Pri riešeníach získaných genetickými algoritmi bolo možné pozorovať vyrovnanejšie rozdelenie zákazníkov medzi jednotlivé vozidlá. Pri modeli GA-CVRP sa prejavila snaha minimalizovať celkovú dĺžku trás, zatiaľ čo pri modeli GA-PRP bolo viditeľné odlišné poradie obsluhy stojísk, ktoré zodpovedá snahe znížiť emisný náklad vhodnejším rozložením zaťaženia vozidla počas trasy.


Priestorové znázornenie najlepších riešení je uvedené na obrázku 9.2 a),b).c) Vizualizácie ukazujú, že Clark-Wrightova heuristika vytvára menej kompaktné trasy a vo viacerých prípadoch prepája vzdialenejšie oblasti menej efektívnym spôsobom. Naopak, riešenia získané genetickými algoritmi pôsobia priestorovo usporiadanejšie. Pri GA-CVRP je zreteľná orientácia na skrátenie celového pohybu vozidiel, zatiaľ čo pri GA-PRP je viditeľné mierne odlišné poradie obsluhy bodov, ktoré zodpovedá snahe znížiť emisný náklad pri meniacom sa zaťažení vozidla.



Obr. 9.2 a) Vizualizácia najlepšieho riešenia podľa Clark-Wrighta



Obr. 9.2 b) Vizualizácia najlepšieho riešenia podľa GA-CVRP




Obr. 9.2 c) Vizualizácia najlepších riešení podľa GA-PRP


9.4. Porovnanie zaťaženia a emisného nákladu vozidiel

Doplňujúci pohľad na výsledné riešenia poskytujú obrázky 9.3 a),b),c), ktorý porovnáva emisný náklad a množstvo odpadu priradené jednotlivým vozidlám. Tento graf umožňuje detailnejšie sledovať, ako boli zákazníci rozdelení medzi vozidlá a ako sa toto rozdelenie premietlo do environmentálnej náročnosti trás.

Z grafu je zrejmé, že genetické algoritmy viedli k vyrovnanejšiemu rozdeleniu odpadu medzi vozidlá než Clarkova-Wrightova heuristika. Pri referenčnom riešení boli dve vozidlá zaťažené takmer na hranicu kapacity, zatiaľ čo zvyšné dve vozidlá obsluhovali menej zaťažené trasy. V prípade GA-CVRP aj GA-PRP je rozloženie záťaže rovnomernejšie, pričom model GA-PRP zároveň dosahuje priaznivejšie rozdelenie emisného nákladu medzi jednotlivé vozidlá. To naznačuje, že pri emisne orientovanom modeli nebolo rozhodujúce len rozdelenie zákazníkov medzi vozidlá, ale aj samotné poradie ich obsluhy.



Obr. 9.3 a) Emisný náklad na vozidlo



Obr. 9.3 b) Hmotnosť odpadu na vozidlo

Na základe uvedených výsledkov možno konštatovať, že oba varianty genetického algoritmu prekonal referenčnú Clarkovu-Wrightovu heuristiku. Model GA-CVRP sa

ukázal ako stabilnejší pri opakovaných behoch a spoľahlivo poskytoval kvalitné riešenia z hľadiska vzdialenosti. Model GA-PRP dosiahol najlepšie individuálne riešenie z hľadiska vzdialenosti aj emisného nákladu, avšak za cenu vyššej variability a dlhšieho výpočtového času. Výsledky tak potvrdzujú, že zohľadnenie environmentálneho kritéria môže viesť k ďalšiemu zlepšeniu kvality riešenia, aj keď si vyžaduje zložitejšie vyhodnocovanie a citlivejšie nastavenie algoritmu.

Záver

Hlavným cieľom diplomovej práce bolo využiť genetický algoritmus pri optimalizácii zvozu komunálneho odpadu a porovnať dva prístupy riešenia, a to model CVRP a zjednodušený model PRP. Tento cieľ vychádzal z charakteru riešenej úlohy, keďže problémy smerovania vozidiel patria medzi NP-tiažké optimalizačné problémy. Pri väčšom počte stojísk preto nie je praktické riešiť ich exaktnými metódami v prijateľnom čase, a z tohto dôvodu bol v práci zvolený evolučný algoritmus, konkrétne genetický algoritmus.

Tomuto cieľu zodpovedala aj štruktúra práce v ktorej boli spracované východiská z oblasti odpadového hospodárstva, modelov smerovania vozidiel a genetických algoritmov. Ďalšia časť bola zameraná na spracovanie reálnych priestorových dát z mestskej časti Bratislava-Ružinov, vytvorenie dištančnej matice, implementáciu genetického algoritmu a porovnanie výsledkov s Clarke-Wrightovou heuristikou.

Dosiahnuté výsledky potvrdili, že genetický algoritmus predstavuje vhodný nástroj na riešenie úloh zvozu komunálneho odpadu. V porovnaní s Clarkovou-Wrightovou heuristikou, ktorá dosiahla vzdialenosť 69,97 km a emisný náklad $0,4396 \times 10^9$ kg·m, priniesol model GA-CVRP výrazné zlepšenie, keď dosiahol vzdialenosť 53,48 km a emisný náklad $0,3340 \times 10^9$ kg·m. To znamená skrátenie trasy o 16,49 km a zníženie emisného nákladu o $0,1056 \times 10^9$ kg·m. Ešte lepší výsledok bol dosiahnutý modelom GA-PRP, ktorý dosiahol vzdialenosť 52,83 km a emisný náklad $0,3293 \times 10^9$ kg·m. V porovnaní s Clarkovou-Wrightovou heuristikou tak išlo o zlepšenie o 17,14 km a o pokles emisného nákladu o $0,1103 \times 10^9$ kg·m. Pri priamom porovnaní oboch genetických prístupov bol model GA-PRP lepší než GA-CVRP o 0,65 km a zároveň dosiahol nižší emisný náklad o $0,0047 \times 10^9$ kg·m.

Za obmedzenie práce možno považovať najmä použitie simulovaných údajov o hmotnosti odpadu a zjednodušený emisný model, ktorý nezachytáva všetky prevádzkové vplyvy reálneho mestského prostredia. Napriek tomu tieto skutočnosti nemenia základný prínos práce, ale skôr vytvárajú priestor na jej ďalšie rozšírenie. V budúcnosti by bolo vhodné pracovať s reálnymi prevádzkovými dátami a doplniť model o ďalšie faktory, napríklad časové okná, dopravnú situáciu alebo heterogénny vozový park.

Na záver možno konštatovať, že cieľ diplomovej práce bol splnený. Bolo preukázané, že genetický algoritmus predstavuje vhodný prístup pri riešení modelov CVRP aj zjednodušeného modelu PRP a že genetický algoritmus ako metaheuristický prístup má

v oblasti odpadového hospodárstva reálny aplikačný potenciál a môže predstavovať užitočný nástroj pri návrhu efektívnejších a udržateľnejších logistických riešení.

Zdroje:

- [1] Mendonca, E. da S. (2018). Genetic algorithm for waste collection in smart cities: Case of Campolide. Master's project, NOVA Information Management School, Universidade Nova de Lisboa.
- [2] Pena et al., (2024). Sustainable waste collection optimization using electric vehicles. In *Sustainable Cities and Society*, Volume 105, Article 105343
<https://doi.org/10.1016/j.scs.2024.105343>
- [3] Cui et al., (2025). Research on optimization of waste sorting and transportation network in smart cities based on garbage volume prediction. In *Discover Computing*, Volume 28, Article 54.
<https://doi.org/10.1007/s10791-025-09537-x>
- [4] Hui, H. & Ponce-Cueto, E. (2015). Waste Collection Vehicle Routing Problem: Literature Review. In *Promet-Traffic & Transportation*, Volume 27.
<https://doi.org/10.7307/ptt.v27i4.1616>
- [5] Khalid et al., (2026). An emission-capacitated vehicle routing model for sustainable urban waste collection using hybrid guided local search. In *Scientific Reports*, Volume 16, Article 14.
<https://doi.org/10.1038/s41598-026-38829-5>
- [6] Bektaş, T. & Laporte, G., (2011). The Pollution-Routing Problem. In *Transportation Research Part B: Methodological*, Volume 45, p. 1232-1250.
<https://doi.org/10.1016/j.trb.2011.02.004>
- [7] Konstantakopoulos, G., (2022). Vehicle routing problem and related algorithms for logistics distribution: a literature review and classification. In *Operational Research*. Volume 22, p. 2033-2062. ISBN:978-1-61197-358-7.
<https://doi.org/10.1007/s12351-020-00600-7>
- [8] Brezina, I. & Pekár J., (2015). Od CVRP k EVRP – VC. V *Nové trendy v ekonometrii a operačním výzkumu: mezinárodní vědecký seminář: zborník*. Bratislava: Vydavateľstvo: EKONÓM, s. 28-33. ISBN: 978-80-225-4181-7.
- [9] Toth, P., & Vigo, D., (2014). *Vehicle Routing: Problems, Methods, and Applications*. Society for Industrial and Applied Mathematics.
<https://doi.org/10.1137/1.9781611973594>
- [10] Li et al., (2023). Optimization of Green Vehicle Paths Considering the Impact of Carbon Emissions: A Case Study of Municipal Solid Waste Collection and Transportation. In *Sustainability*, Volume 15(22), p. 1-16.
<https://doi.org/10.3390/su152216128>
- [11] Mitchell, M., (1996). *An Introduction to Genetic Algorithms*. Cambridge: The MIT Press. ISBN: 978-0-26213-316-6.
<https://doi.org/10.7551/mitpress/3927.001.0001>

- [12] Goldberg, D. E., (1989). Genetic Algorithms in Search, Optimization, and Machine Learning. Addison-Wesley Publishing Company. ISBN: 978-0-201-15767-3.
<https://doi.org/10.5860/choice.27-0936>
- [13] Holland, J. H., (1975). Adaptation in Natural and Artificial Systems. University of Michigan Press. ISBN: 978-0-26258-111-0
- [14] Overpass API.(2024). https://wiki.openstreetmap.org/wiki/Overpass_API
- [15] Overpass turbo. <https://overpass-turbo.eu/>
- [16] OpenRouteService. <https://openrouteservice.org/services/>
- [17] Clark, G. & Wright, J.W, (1964). Scheduling of Vehicles from a Central Depot to a Number of Delivery Points. In Operations Research, Volume 12, p. 568-581.
<https://doi.org/10.1287/opre.12.4.568>

Prílohy

Celý kód aj so zdrojovými dátami je dostupný na adrese:

https://github.com/Simona1010/DP_Geneticke_algoritmy_v_environmentalnej_optimalizacii